

UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
Departamento de Ingeniería Informática



Laboratorio 1
Diabetic Retinopathy Debrecen

Integrantes: Gonzalo Ahumada
Daniel Muñoz
Asignatura: Inteligencia Computacional
Profesor: Max Chacón
Ayudante: Sebastián Chávez

4 de mayo de 2026

Tabla de contenidos

1. Introducción	1
1.1. Contextualización y Antecedentes	1
1.2. Objetivos del Laboratorio	2
1.3. Formulación de Hipótesis	3
2. Descripción del Problema	3
2.1. Descripción de la Base de Datos (Diabetic Retinopathy Debrecen) . . .	3
2.2. Descripción de Clases y Variables	4
2.2.1. Variables de Calidad y Pre-procesamiento	4
2.2.2. Detección de Lesiones y Niveles de Confianza	4
2.2.3. Descriptores Anatómicos	5
2.2.4. Variable de Clase (Objetivo)	5
3. Marco Teórico	6
3.1. Retinopatía Diabética e Importancia Médica de las Lesiones	6
3.2. Fundamentos de Estadística Descriptiva y Forma de Distribución . . .	7
3.3. Fundamentos de Estadística Inferencial y Pruebas de Hipótesis	9
4. Análisis Estadístico e Inferencial	12
4.1. Resumen Estadístico Descriptivo	12
4.2. Análisis de la Forma de la Distribución (Asimetría y Curtosis)	14
4.3. Validación de Normalidad (Prueba de Shapiro-Wilk)	16
4.4. Detección de Valores Atípicos (Outliers)	17
4.4.1. Resultados de la Detección	17
4.4.2. Visualización mediante Boxplots por Clase	18
4.5. Análisis de Correlación y Visualización (Heatmap)	20
4.5.1. Interpretación del Mapa de Calor	20
4.5.2. Conclusión del Análisis de Correlación	23
4.6. Comparación de Grupos (Prueba Mann-Whitney U)	23
4.6.1. Planteamiento de Hipótesis	24

4.6.2.	Resultados de la Prueba	24
4.6.3.	Interpretación de los Hallazgos	24
4.7.	Homogeneidad de Varianzas (Test de Levene)	26
4.7.1.	Planteamiento de Hipótesis	26
4.7.2.	Resultados	26
4.7.3.	Interpretación	27
4.8.	Modelamiento mediante Regresión Logística	27
4.8.1.	Justificación de la Selección de Atributos	28
4.8.2.	Evaluación Global y Bondad de Ajuste	29
4.8.3.	Interpretación de los Coeficientes y Significancia	30
4.8.4.	Evaluación de Desempeño (Matriz de Confusión y ROC)	30
4.8.5.	Validación de Residuos	31
5.	Conclusiones	33
5.1.	Síntesis de Hallazgos Principales	33
5.2.	Discusión de Resultados y Desempeño del Modelo	33
5.3.	Limitaciones y Proyecciones Futuras	34
	Bibliografía	37

1. Introducción

1.1. Contextualización y Antecedentes

Las personas con diabetes pueden tener una enfermedad ocular llamada retinopatía diabética. Esta enfermedad ocurre por niveles altos de azúcar en la sangre los cuales causan daño a los vasos sanguíneos en la retina, estos pueden hincharse y tener fugas o también pueden cerrarse e impedir que la sangre fluya e incluso a veces, se generan nuevos vasos sanguíneos anormales en la retina. Todos estos cambios pueden provocar la pérdida de visión.

La retinopatía diabética (RD) representa una de las principales causas de pérdida de visión a nivel mundial y es considerada una “enfermedad silenciosa”, ya que a menudo progresa sin síntomas visibles hasta etapas avanzadas en que las posibilidades de recuperación visual son reducidas (Casanova et al., 2014).

Se puede tener retinopatía diabética y no saberlo. Esto se debe a que generalmente no presenta síntomas en sus etapas tempranas, pero a medida que empeora, se pueden notar los siguientes síntomas: visión borrosa, visión que cambia de borrosa a clara, ver áreas en blanco o oscuras en el campo de visión, visión nocturna deficiente, notar que los colores se ven atenuados o apagados y perder la visión.

La detección temprana es fundamental para permitir intervenciones terapéuticas eficaces, pero los métodos tradicionales de examen clínico enfrentan diferentes barreras, por ejemplo como que un mismo examen de retina pueda ser analizado por diferentes médicos llegando a diferentes conclusiones o también la falta de especialistas en zonas rurales, lo que imposibilita el acceso a los pacientes a un diagnóstico temprano de la enfermedad (Casanova et al., 2014). Esto ha impulsado el desarrollo de sistemas computacionales que se encargan de analizar imágenes de retina de manera automática, entregando un diagnóstico objetivo y que a la vez le sirve para retroalimentar los modelos y mejorar el diagnóstico (Antal & Hajdu, 2014b).

Para el desarrollo de este laboratorio, se analiza el conjunto de datos *Diabetic Retinopathy Debrecen*, el cual consiste en 1.151 registros de fotografías de retina de diferentes pacientes con 19 atributos. Los valores de estos atributos se obtuvieron gracias

al conjunto de imágenes *Messidor*, que es una base de datos de imágenes retinales de hospitales franceses. (Antal & Hajdu, 2014a). Estos atributos capturan características críticas para el diagnóstico, incluyendo el conteo de microaneurismas detectados con distintos grados de confianza, cantidad normalizada de exudados (depósitos de grasa que se acumulan en la retina cuando los vasos sanguíneos presentan daño) y descriptores anatómicos como la distancia entre la mácula y el disco óptico (Antal & Hajdu, 2014a). La literatura científica sugiere que el conteo de microaneurismas es el factor de mayor peso para discriminar la presencia de la enfermedad en modelos computacionales (Casanova et al., 2014), es por esto que existen 6 variables con diferentes niveles de confianza (ma1 a ma6) para analizar lo que puede llegar a ser un microaneurisma, estos niveles de confianza se conocen como confidence threshold.

1.2. Objetivos del Laboratorio

General: Estudiar e interpretar los datos del dataset seleccionado para obtener información objetiva sobre cómo poder detectar la Retinopatía Diabética (RD) en un paciente, más aún sabiendo que es un diagnóstico difícil si no se analizan imágenes retinales por sistemas computacionales. Además de lo anterior, la información entregada por el dataset permite descubrir cuáles atributos son más importantes para el diagnóstico objetivo de esta enfermedad. Por último, este análisis permite concientizar sobre una de las enfermedades con menos oportunidad de descubrimiento en etapas iniciales, lo cual nos hace reflexionar sobre lo importante que es contar con ayuda tecnológica para el bienestar y salud de pacientes que incluso ya cuentan con una enfermedad de base como lo es la diabetes (Antal & Hajdu, 2014a).

Específicos:

1. Realizar un análisis estadístico descriptivo para resumir las características fundamentales del conjunto de datos.
2. Aplicar técnicas de estadística inferencial, incluyendo pruebas de normalidad y de hipótesis, para obtener conclusiones de los resultados obtenidos.

3. Identificar qué variables presentan diferencias significativas entre pacientes sanos y aquellos con signos de la patología.

1.3. Formulación de Hipótesis

Basándose en la literatura científica (Casanova et al., 2014), se postula que: las variables relacionadas con el conteo de microaneurismas (`ma1` a `ma6`) y la detección de exudados (`exudate1` a `exudate8`) constituyen los principales marcadores clínicos para discriminar entre pacientes sanos y pacientes con retinopatía diabética, superando incluso a las variables anatómicas estructurales como el diámetro del disco óptico, la distancia mácula-disco, entre otras.

2. Descripción del Problema

2.1. Descripción de la Base de Datos (Diabetic Retinopathy Debrecen)

Este conjunto de datos contiene atributos extraídos del set de imágenes **Messidor** (Antal & Hajdu, 2014a). Messidor es una base de imágenes retinales desarrollada por hospitales universitarios de Francia, ampliamente utilizada como referencia en investigación de diagnóstico automatizado de retinopatía diabética. Consta de 1.151 retinografías y 19 atributos que representan lesiones detectadas, rasgos anatómicos (distancia mácula-disco óptico) y descriptores de nivel de imagen (Antal & Hajdu, 2014a). El dataset es de naturaleza multivariada, debido a que contamos con diferentes tipos de variables con las cuales podemos decidir si el paciente está o no enfermo. Este conjunto de datos nos indica principalmente si existe o no enfermedad, es decir, la clasificación y análisis de variables da como resultado: clase 1 para signos de RD y clase 0 para ausencia (Antal & Hajdu, 2014a).

2.2. Descripción de Clases y Variables

A continuación, se detalla la naturaleza y relevancia de cada una de las 19 variables del conjunto de datos:

2.2.1. Variables de Calidad y Pre-procesamiento

- **quality**: Indicador binario de la calidad de la retinografía (0 = calidad insuficiente para el diagnóstico, 1 = calidad suficiente).
- **pre_screening**: Indicador binario de una revisión preliminar automática de la imagen, donde el valor 1 señala la detección de una anomalía retiniana grave que justifica un análisis más profundo, y 0 indica ausencia de señales de alerta.
- **am_fm_classification**: Resultado binario de un análisis matemático para detectar si hay estructuras que “rompen” el patrón normal de una retina sana. Si la señal AM-FM detecta muchas variaciones bruscas, es un indicador fuerte de que hay patología (lesiones).

2.2.2. Detección de Lesiones y Niveles de Confianza

- **ma1 a ma6** (Microaneurismas): Representan el conteo de microaneurismas (MA) detectados mediante algoritmos de procesamiento de imágenes. La literatura identifica a los microaneurismas como el factor de mayor importancia para discriminar la presencia de la enfermedad. Podemos indicar aquí que un microaneurisma es un pequeño punto rojo, y que estas variables son el conteo físico de esas lesiones.
 - **Nota técnica sobre los niveles de confianza**: La distinción entre estas seis variables radica en el nivel de confianza (α) del algoritmo, que escala desde $\alpha = 0,5$ (**ma1**) hasta $\alpha = 1,0$ (**ma6**). Un nivel de confianza más elevado indica criterios de detección más estrictos, lo que reduce la probabilidad de falsos positivos pero incrementa el riesgo de omitir lesiones reales y sutiles.
- **exudate1 a exudate8**: Representan la presencia de exudados (principalmente depósitos de lípidos y proteínas). A diferencia de los microaneurismas, estos valores

no son conteos simples, sino que están normalizados: Se divide el número de lesiones detectadas por el diámetro de la Región de Interés (ROI). Esto permite identificar cuanta densidad de exudados existe en la retina, independiente de cuán cerca o lejos se tomó la imagen.

- **Nota sobre calidad del dataset:** El análisis exploratorio reveló que las columnas `exudate3` y `exudate4` son **idénticas** en todos los registros del dataset. Esta redundancia es una característica del conjunto de datos original publicado en UCI y es propio del diseño del algoritmo original y debe considerarse en futuros análisis de reducción de variables, para no dar mas peso a una variable que contiene el mismo dato.

2.2.3. Descriptores Anatómicos

- `euclidean_distance`: Mide qué tan lejos está el centro del ojo del nervio óptico. Es vital para localizar la fovea (donde vemos con detalle).
- `optic_disc_diameter`: Medida del diámetro del disco óptico.

2.2.4. Variable de Clase (Objetivo)

Class: Indica el estado del diagnóstico del paciente.

- 1: Indica que la imagen presenta signos de retinopatía diabética. Este valor agrupa los grados 1, 2 y 3 de severidad de la base Messidor, que van desde la presencia de microaneurismas leves hasta hemorragias y formación de nuevos vasos sanguíneos. En este punto se hace una simplificación de la información de los grados de severidad. Importando solo que el paciente presenta signos de la enfermedad.
- 0: Corresponde al grado 0 de Messidor, es decir, ausencia total de lesiones retinales detectables.

3. Marco Teórico

3.1. Retinopatía Diabética e Importancia Médica de las Lesiones

La retinopatía diabética (RD) es una de las principales causas de ceguera en el mundo y se caracteriza por ser una “enfermedad silenciosa” que progresa sin síntomas hasta etapas críticas (Casanova et al., 2014).

Ya en el año 2003 el estudio de la retinopatía diabética hacía patente que esta enfermedad no se diagnostica por cambios de nervio óptico, sino que por una serie de lesiones jerárquicas: primero aparecen los microaneurismas, luego las hemorragias y por último los exudados. (Wilkinson et al., 2003). En este punto entendemos la riqueza en la información proporcionada por el dataset utilizado.

Importante recalcar que gracias al procesamiento digital de imágenes retinales y a los modelos de aprendizaje automático es que podemos llegar a saber qué partes del ojo delatan esta enfermedad y también qué tan avanzada está.

Existen dos indicadores clave para clasificar a un paciente como sano o enfermo: los microaneurismas y los exudados.

- **Microaneurismas (MA):** Son las lesiones clínicas más tempranas de la RD. Consisten en pequeñas dilataciones en las paredes de los capilares retinales, causadas por el debilitamiento estructural provocado por niveles elevados de glucosa en la sangre. En imágenes de fondo de ojo (retinografía) se visualizan como puntos rojos diminutos y circulares con bordes bien definidos, es interesante indicar que el contraste frente al fondo anaranjado de la retina permite su identificación mediante filtros morfológicos (Antal & Hajdu, 2014b). Su conteo es el principal indicador de la etapa inicial de la enfermedad y el factor más relevante para discriminar computacionalmente la presencia de RD (Casanova et al., 2014).
- **Exudados:** Depósitos que aparecen cuando los vasos dañados filtran fluidos hacia el tejido retinal, indicando avance de la enfermedad hacia etapas moderadas o severas. En el análisis de datos, el área de los exudados se normaliza según el

diámetro de la Región de Interés (ROI) para compensar variaciones en el tamaño de las imágenes (Antal & Hajdu, 2014a). Podemos encontrar dos tipos:

- **Exudados duros:** Son depósitos de lípidos (grasas) y proteínas que se filtran desde el torrente sanguíneo hacia la retina. Se presentan como manchas pequeñas, brillantes y de tono amarillento.
- **Exudados blandos (manchas algodinosas):** Áreas de infarto (isquemia) donde el tejido nervioso muere por falta de oxígeno. Podemos identificarlas como manchas blancas más grandes con bordes difusos, indicativas de un avance en la enfermedad más severo.

Nota metodológica: La distinción clínica entre exudados duros y blandos se incluye en este trabajo con fines estrictamente informativos. Para efectos del análisis computacional y el procesamiento del dataset, se utiliza el bloque consolidado de variables que comprende desde `exudate1` hasta `exudate8`, las cuales capturan la densidad total de estas lesiones sin realizar una separación explícita en la clasificación del conjunto de datos.

3.2. Fundamentos de Estadística Descriptiva y Forma de Distribución

En estadística descriptiva buscamos indicadores que sean claves para comprender el comportamiento de las variables del conjunto de datos. En este análisis se responden preguntas como ¿dónde están concentrados los datos? ¿qué tan dispersos están? ¿hay valores extremos?

“Este análisis descriptivo permitirá confirmar si la distribución de los microaneurismas y exudados presenta una variabilidad significativa entre pacientes sanos y enfermos, validando su importancia como indicadores diagnósticos”

- **Medidas de tendencia central y dispersión:** Parámetros básicos que nos permiten comprender qué tan variados son los datos de nuestro conjunto, qué tan diferentes son entre sí; este análisis nos permite descubrir patrones de enfermedad.

Media aritmética: Es el promedio tradicional. Nos da una idea del valor «típico» de la variable sumando todos los casos y dividiendo por el total.

Mediana: Es el valor central cuando ordenamos los datos de menor a mayor. A diferencia de la media, es una medida robusta, lo que significa que no se ve afectada por valores extremadamente altos o bajos que no permitirían representar el comportamiento general de los datos.

Desviación estándar: Nos indica qué tan diferentes son los datos respecto al promedio. Una desviación alta significa que los datos están muy dispersos, que pueden existir valores atípicos con respecto al promedio; una baja, que están muy agrupados cerca del centro (promedio), valores que se asemejen más. Respondemos a la pregunta: ¿Qué tan diferentes son los pacientes entre sí respecto al promedio?

- **Forma de la distribución:** No basta con saber el centro; hay que saber cómo se “dibuja” el conjunto de datos.

Asimetría (*Skewness*): Nos dice si los datos se inclinan hacia un lado. Nos indica si la mayoría de los pacientes tienen valores bajos o altos de una lesión. Se responde a la pregunta: ¿Hacia dónde se inclina la balanza de pacientes? (Sanos vs. Graves).

Curtosis: Esta medición nos sirve para encontrar las sorpresas en el conjunto de datos, como por ejemplo, si hay muchos pacientes con valores similares (alta curtosis) o concentración de datos, inferimos entonces que la mayoría de los pacientes tienen valores de la variable similares o iguales, pero hay una probabilidad real de encontrar casos con valores que salen de lo común y se van a los extremos. Es una medición que nos invita a fijarnos en los datos extremos para que podamos identificarlos y que estos no afecten nuestros cálculos. Podemos encontrar dónde están concentrados nuestros datos y también podemos saber si estos casos extremos son raros o son comunes dependiendo de si la curtosis es alta o baja.

- **Detección de valores atípicos (*Outliers*):** ¿Qué es un outlier? Es un valor que se aleja tanto del resto que puede parecer no pertenecer al mismo grupo o

conjunto de datos. Una vez que la asimetría y la curtosis nos advierten que existen datos extremos, utilizamos el Método de Tukey para identificarlos con precisión.

¿Por qué importa detectarlos? Porque pueden distorsionar el análisis. Podríamos obtener el promedio de un conjunto de datos y no representar la realidad del mismo al considerar datos que salen de lo común y son poco representativos con respecto al conjunto general.

¿Qué es el método de Tukey?

Es la técnica más usada para detectar outliers de forma objetiva. Funciona de la siguiente manera:

1. Toma el 25 % inferior de los datos ($Q1$) y el 75 % superior ($Q3$).
2. Calcula la distancia entre ellos: $IQR = Q3 - Q1$.
3. Define un límite inferior: $Q1 - 1,5 \times IQR$.
4. Define un límite superior: $Q3 + 1,5 \times IQR$.
5. Todo lo que queda fuera de esos límites es un outlier.

3.3. Fundamentos de Estadística Inferencial y Pruebas de Hipótesis

Mientras que el análisis descriptivo solo describe lo que vemos, la inferencial va más allá — te permite sacar conclusiones y tomar decisiones basadas en los datos. La pregunta clave es: ¿lo que observo en mi muestra es real o es producto de la suerte?

Por ejemplo: veo que los pacientes enfermos tienen más microaneurismas que los sanos. Pero ¿esa diferencia es real o simplemente mi elección al seleccionar los pacientes del estudio no fue la mejor?

Las pruebas de hipótesis responden esa pregunta matemáticamente.

Entre las pruebas de hipótesis que se utilizan en este análisis se encuentran:

- **Prueba de normalidad (Shapiro-Wilk):**

Antes de aplicar cualquier prueba estadística, necesitas saber cómo se distribuyen nuestros datos — si siguen una distribución normal o no.

¿Por qué importa? Porque muchas pruebas estadísticas asumen que los datos son normales. Si no lo son, debemos usar pruebas distintas.

Shapiro-Wilk responde: ¿mis datos se comportan como una distribución normal?

Para responder la pregunta anterior es que tenemos el p-valor, una medida que nos permite decidir si rechazamos o no la hipótesis de normalidad y su límite es 0.05.

- Si $p\text{-valor} < 0,05 \rightarrow$ No son normales $\rightarrow$ usas pruebas no paramétricas (Pruebas más robustas).
- Si $p\text{-valor} > 0,05 \rightarrow$ Podrían ser normales $\rightarrow$ puedes usar pruebas paramétricas.

■ Comparación de grupos (prueba Mann-Whitney U):

Una vez que sabemos que los datos no son normales, necesitamos una prueba que compare dos grupos sin asumir normalidad. Es la herramienta que decide si hay una diferencia real entre los sanos y los enfermos.

Mann-Whitney U responde: ¿la distribución de esta variable es significativamente distinta entre pacientes sanos y enfermos?

- Si $p\text{-valor} < 0,05 \rightarrow$ Sí hay diferencia real entre los grupos.
- Si $p\text{-valor} > 0,05 \rightarrow$ No hay evidencia de diferencia.

■ Homocedasticidad (Test de Levene):

Se utiliza para evaluar la igualdad de varianzas entre diferentes grupos, en este caso grupo de pacientes sanos y enfermos.

Homocedasticidad es una palabra técnica que significa simplemente: ¿las varianzas de los dos grupos son iguales?

La varianza mide qué tan dispersos están los datos. Si los pacientes sanos tienen todos valores similares de microaneurismas pero los enfermos tienen valores muy dispersos, las varianzas son distintas — hay heterocedasticidad.

Levene responde: ¿la dispersión de esta variable es igual en ambos grupos?

Sirve para entender cómo se comporta la enfermedad. Si los enfermos tienen una varianza mucho más alta que los sanos, confirmas que la retinopatía afecta a cada persona de forma muy distinta (mucha variabilidad), mientras que los sanos son un grupo muy uniforme.

- Si $p\text{-valor} < 0,05 \rightarrow$ Las varianzas son distintas.
- Si $p\text{-valor} > 0,05 \rightarrow$ Las varianzas son iguales.

4. Análisis Estadístico e Inferencial

En esta sección se presentan los resultados del análisis de los 19 atributos del dataset **Diabetic Retinopathy Debrecen**. Para el desarrollo técnico se emplearon las siguientes bibliotecas de Python: *ucimlrepo* (Kelly et al., 2023) para la importación directa del dataset, *Pandas* (Team, 2024) para el manejo y estadística descriptiva de los datos, *NumPy* (Harris et al., 2020) para operaciones numéricas, *SciPy* (`scipy.stats`) (Virtanen et al., 2020) para las pruebas estadísticas inferenciales, *Matplotlib* (Hunter, 2007) y *Seaborn* (Waskom, 2021) para la generación de visualizaciones, y *Scikit-learn* (Pedregosa et al., 2011) para el modelo de regresión logística y las métricas de evaluación.

4.1. Resumen Estadístico Descriptivo

La Tabla 1 presenta los estadísticos descriptivos de las 19 variables del dataset. Todas las variables cuentan con 1.151 retinografías completas, esto es importante ya que cada dato de cada celda es posible de utilizar para el análisis estadístico.

Del análisis de la tabla se extraen las siguientes observaciones relevantes:

- **Calidad del dataset:** La variable `quality` presenta una media de 0,997, lo que indica que prácticamente la totalidad de las imágenes tienen calidad suficiente para el diagnóstico. Podemos garantizar entonces que nuestro análisis sobre los microaneurismas es confiable, ya que las imágenes tienen excelente calidad para el análisis.
- **Patrón decreciente en microaneurismas:** Las medias de `ma1` a `ma6` disminuyen progresivamente ($38,4 \rightarrow 21,2$), lo cual concuerda con el aumento del nivel de confianza del algoritmo: a mayor exigencia, menos microaneurismas son contabilizados para poder obtener un diagnóstico más confiable.
- **Alta variabilidad en exudados:** `exudate1` La variable `exudate1` muestra una desviación estándar (58,5) muy similar a su media (64,1). Esto indica una alta dispersión de los datos, reflejando la heterogeneidad de la muestra. Mientras que

Tabla 1: Tabla de estadísticos descriptivos, los nombres y siglas están en inglés.

Variable	count	mean	std	min	max
quality	1151	0.996525	0.0588742	0	1
pre_screening	1151	0.918332	0.273977	0	1
ma1	1151	38.4283	25.6209	1	151
ma2	1151	36.9096	24.1056	1	132
ma3	1151	35.1407	22.8054	1	120
ma4	1151	32.2971	21.1148	1	105
ma5	1151	28.7472	19.5092	1	97
ma6	1151	21.1512	15.1016	1	89
exudate1	1151	64.0967	58.4853	0.349274	403.939
exudate2	1151	23.088	21.6027	0	167.131
exudate3	1151	8.70461	11.5676	0	106.07
exudate4	1151	8.70461	11.5676	0	106.07
exudate5	1151	0.560738	2.48411	0	51.4232
exudate6	1151	0.21229	1.05713	0	20.0986
exudate7	1151	0.0856741	0.398717	0	5.9378
exudate8	1151	0.0372251	0.178959	0	3.08675
macula_opticdisc_distance	1151	0.523212	0.0280554	0.367762	0.592217
opticdisc_diameter	1151	0.108431	0.0179448	0.057906	0.219199
am_fm_classification	1151	0.336229	0.472624	0	1

gran parte de los pacientes (sanos) presentan valores cercanos a cero, otros (enfermos críticos) alcanzan valores extremos de hasta 403,9. Esta variabilidad es fundamental para la clasificación, ya que permite al modelo identificar con mayor certeza una persona sana de una enferma. Recalcar que si todos los pacientes estuvieran en la misma etapa de la enfermedad, los valores serían más parecidos (homogéneos).

- **Estabilidad de variables anatómicas:** `macula_opticdisc_distance` y `opticdisc_diameter` Como estas variables apenas varían entre personas (son casi constantes), es poco probable que sirvan para distinguir a una persona enferma de una sana, a diferencia de los microaneurismas que varían mucho entre personas.
- **Redundancia detectada:** Las columnas `exudate3` y `exudate4` Se identificó que las columnas `exudate3` y `exudate4` presentan valores estadísticos idénticos, lo que sugiere que ambas variables aportan la misma información diagnóstica. Para optimizar el análisis y evitar sesgos por duplicidad, es recomendable tratar estas columnas como una sola unidad informativa en etapas posteriores de modelado.

4.2. Análisis de la Forma de la Distribución (Asimetría y Curtosis)

Para las variables críticas de microaneurismas (`ma1` a `ma6`), identificadas en la literatura (Casanova et al., 2014) como los predictores más importantes para la detección de la RD, se evaluó su asimetría y curtosis:

Todos los números de la columna «Asimetría» son positivos (entre 0.49 y 0.74). La mayoría de los 1,151 pacientes están «agrupados» en valores bajos (pocos microaneurismas) cercanos al cero. Pero existen casos más graves que llevan a que la distribución tenga una cola larga hacia la derecha (valores altos de microaneurismas). Esto es típico en enfermedades donde la mayoría de los pacientes están en etapas iniciales o son sanos, y solo una minoría presenta formas avanzadas con muchos microaneurismas. La variable `ma1` es la más asimétrica (0.74). Esto es lógico, porque al ser el filtro más

Tabla 2: Tabla de asimetría y curtosis para los microaneurismas.

Variable	Asimetría (skew)	Curtosis
ma1	0.743916	0.333756
ma2	0.62517	-0.0999926
ma3	0.532673	-0.468193
ma4	0.498474	-0.673164
ma5	0.533248	-0.692618
ma6	0.722384	-0.102349

permisivo utilizando el criterio de confianza ($\alpha = 0,5$), es donde más se nota la diferencia entre un paciente sano y un enfermo grave, porque captura un espectro más amplio de lesiones en pacientes con la enfermedad avanzada.

Los valores negativos de curtosis en las variables de microaneurismas (especialmente en ma4 y ma5 con -0,69) revelan distribuciones de tipo platicúrtico. Esto indica que los conteos de lesiones no tienen la forma de una campana o montaña, sino que presentan una dispersión más uniforme, más aplanada. Esta característica sugiere una transición gradual entre los distintos grados de severidad de la enfermedad, lo que facilita el entrenamiento de modelos de clasificación al contar con una representación equilibrada de la progresión patológica. En una curtosis negativa, los datos están más «repartidos» a lo largo del eje. No hay un solo valor que domine, sino que es una transición gradual entre pacientes sanos y enfermos.

La variable ma1 es ligeramente más puntiaguda (Leptocúrtica), es decir curtosis positiva. Como esta variable cuenta con un filtro más permisivo se detectan más lesiones hasta las más pequeñas, generando este pequeño monte, esto ocurre porque una gran cantidad de pacientes se «amontonan» en valores bajos muy parecidos entre sí.

4.3. Validación de Normalidad (Prueba de Shapiro-Wilk)

La prueba de Shapiro-Wilk aplicada a las variables de microaneurismas (ma1 a ma6) nos indica un resultado unánime: ninguna variable sigue una distribución normal.

Tabla 3: Tabla de validación de normalidad para los microaneurismas.

Variable	W	p-value	Distribución
ma1	0.945107	$2,94 \times 10^{-20}$	No Normal
ma2	0.950456	$3,02 \times 10^{-19}$	No Normal
ma3	0.950985	$3,84 \times 10^{-19}$	No Normal
ma4	0.947417	$7,86 \times 10^{-20}$	No Normal
ma5	0.938654	$2,18 \times 10^{-21}$	No Normal
ma6	0.929734	$8,23 \times 10^{-23}$	No Normal

Debemos enfocarnos en los valores de la columna p-value, todos del orden de 10^{-20} , 10^{-21} , 10^{-23} : números extremadamente pequeños, prácticamente cero.

Para comprender la magnitud de estos valores, consideremos el siguiente ejemplo con ma1:

- **Umbral de decisión (p-value):** 0,05
- **p-valor obtenido:** $2,94 \times 10^{-20} \approx 0,00000000000000000000294$
- **Conclusión:** es decir, millones de veces más pequeño que el umbral (p-value $< 0,05$)

Lo anterior significa que la probabilidad de que estos datos provengan de una distribución normal es prácticamente inexistente.

Enfocándonos en la columna Distribución, todos los resultados indican “No Normal”. La conclusión es unánime para las 6 variables: la no normalidad es contundente. Los p-valores están muy lejos del umbral, por lo que no existe duda estadística.

El resultado de esta prueba es la «luz verde» para usar la Prueba de Mann-Whitney U. Como los datos no son normales, esta prueba no paramétrica es la única forma de comparar a los pacientes sanos frente a los enfermos.

4.4. Detección de Valores Atípicos (Outliers)

Aplicando el método de Tukey sobre las variables de microaneurismas (cuya formulación se detalla en el Marco Teórico), se identificaron los pacientes con conteos de lesiones inusualmente altos o bajos respecto al comportamiento general de la muestra. Los resultados se presentan a continuación:

4.4.1. Resultados de la Detección

Se analizaron los atributos de microaneurismas (**ma1** a **ma6**), los cuales representan el conteo de lesiones detectadas con niveles de confianza crecientes ($\alpha = 0,5$ a $1,0$). Los resultados obtenidos se detallan en la siguiente tabla:

Tabla 4: Outliers identificados en variables de microaneurismas.

Variable	Outliers Identificados	Índices
ma1	7	[129, 280, 332, 339, 560, 575, 1077]
ma2	6	[129, 280, 332, 339, 575, 1077]
ma3	4	[332, 339, 575, 1077]
ma4	1	[339]
ma5	1	[271]
ma6	3	[14, 271, 648]

Validación Clínica y Correlación con la Patología

El número de outliers disminuye. El número de outliers disminuye a medida que aumenta el nivel de confianza: a mayor exigencia del detector, se contabilizan menos lesiones y, por ende, también se reducen los valores extremos.

Anomalía en ma6. Se observa algo interesante en esta tendencia al llegar a ma6, donde el conteo de outliers sube a 3. Esto no es un error; el filtro ma6 es extremadamente selectivo y, al reducirse el conteo general de lesiones en toda la muestra, cualquier rastro de enfermedad se vuelve más evidente, haciendo que los pacientes con patología confirmada destaquen como casos excepcionales.

Índices recurrentes. Revisando la columna **Índices**, varios números aparecen en múltiples filas. El paciente 339, por ejemplo, es outlier en ma1, ma2, ma3 y ma4: no es un error de un solo filtro, sino una persona con una carga de lesiones tan extrema que todos los niveles de confianza lo marcan como caso extraordinario. Es, probablemente, uno de los pacientes más graves del dataset.

Validación clínica. Al cruzar los índices con la columna **Class**, prácticamente todos corresponden a pacientes con retinopatía diabética, confirmando que son casos reales de enfermedad severa y no errores de medición. La única excepción es el **Índice 14** (Clase 0, sano): bajo el criterio más estricto ($\alpha = 1,0$), el detector identificó estructuras en su retina como microaneurismas confirmados pese a que el paciente fue clasificado como sano. Posiblemente se trate de un caso *borderline* o de una etapa muy temprana aún no diagnosticada.

4.4.2. Visualización mediante Boxplots por Clase

Los boxplots (o diagramas de caja) permiten comparar cómo se distribuyen los microaneurismas entre personas sanas y enfermas. Podemos ver claramente cómo están repartidos los datos de los pacientes dentro de cada grupo.

Interpretación de la Figura

1. **Clase 1 siempre por encima de Clase 0:** En todas las variables ma1 a ma6, las cajas naranjas (enfermos) están siempre por encima de las verdes (sanos). Los pacientes con retinopatía diabética presentan mayor conteo de microaneurismas en todos los niveles de confianza del detector.
2. **Solapamiento entre clases:** Si miramos el diagrama, veremos que en algún




Figura 1: Diagrama de cajas entre las Clases 0 y 1.

punto del eje y ambas cajas comparten espacio (cantidad de lesiones), a esto se le llama solapamiento y nos indica que por ejemplo existen pacientes sanos con 30 MA y pacientes enfermos con 30 MA. Si, solo nos enfocamos en esa zona, no podemos inferir que paciente es quien. Esto puede ocurrir porque en etapas tempranas de la enfermedad un paciente grado 1 tiene pocas lesiones y puede parecerse mucho al estado clínico de un paciente sano con respecto a la cantidad de lesiones. Debido a lo anterior es que necesitamos la Prueba de Mann-Whitney U para determinar si la diferencia entre ambos grupos es estadísticamente significativa y real a pesar del solapamiento.

3. **Outliers visibles:** Los puntos aislados que superan los 140 microaneurismas en ma1 corresponden exactamente a los índices identificados con el método de Tukey, todos pertenecientes a la Clase 1. Es importante recalcar que ambos grupos presentan valores atípicos (outliers); sin embargo, existe una diferencia cualitativa entre ellos. Los outliers del grupo con Retinopatía (Clase 1) no solo son más frecuentes, sino que alcanzan magnitudes significativamente superiores (superando los 140 microaneurismas en ma1). Por otro lado, la presencia de outliers en el grupo sano (Clase 0) sugiere la existencia de variabilidad biológica o casos en etapas subclínicas muy tempranas que, si bien son estadísticamente atípicos para su grupo, no alcanzan los niveles críticos observados en los grupos con enfermedad,

por ende no se diagnosticó la enfermedad. Esto sucede en la variable `ma1`, `ma5` y `ma6`, donde podemos observar los círculos arriba de las cajas verdes.

4. **Reducción de dispersión hacia `ma6`:** Tanto las cajas verdes como las naranjas se hacen más pequeñas y bajas de `ma1` a `ma6`, confirmando visualmente el patrón decreciente en ambos grupos a mayor nivel de confianza del algoritmo porque se detectan menos lesiones y por ende existe menos variabilidad.

4.5. Análisis de Correlación y Visualización (Heatmap)

Para identificar las relaciones lineales entre los 19 atributos y la variable de diagnóstico (`Class`), se calculó la matriz de correlación de Pearson utilizando las librerías `pandas` (Team, 2024) y `seaborn` (Waskom, 2021) en Python. Sirve para identificar patrones de asociación. Si una variable sube, ¿la otra también sube (correlación positiva)? ¿O baja (correlación negativa)? Esto ayuda a entender qué variables «trabajan juntas» para detectar la enfermedad.

4.5.1. Interpretación del Mapa de Calor

El análisis visual del mapa de calor permite extraer las siguientes conclusiones técnicas:

1. **Alta Colinealidad en Microaneurismas (`ma1` a `ma6`):** Se observa una correlación positiva extremadamente alta, cercana a 1,00 en la mayoría de los casos. Por ejemplo, la correlación entre `ma1` y `ma2` es de 1,00, y entre `ma1` y `ma3` es de 0,99. Es lógico: si un filtro detecta muchos microaneurismas, los otros también lo harán.
 - *Fundamentación:* Esto confirma que estos atributos representan el mismo fenómeno clínico (conteo de microaneurismas) detectado con niveles de confianza (α) crecientes. La alta redundancia sugiere que, para futuros modelos de clasificación, se podría realizar una reducción de dimensionalidad sin perder información crítica.




Figura 2: Mapa de calor basado en la matriz de correlaciones.

2. **Correlación con la Variable Objetivo (Class):** Si miramos el mapa de calor veremos valores como 0.29 para `ma1` o 0.18 para `exudate8`.

- Aunque parecen números bajos, en medicina son significativos. Indican que a medida que aumentan las lesiones, aumenta la probabilidad de estar enfermo. Confirma que los microaneurismas (`ma1`) tienen la correlación más alta con la enfermedad, por encima del diámetro del disco óptico.
- *Significancia:* Este hallazgo es coherente con el estudio de Casanova et al. (2014), el cual establece mediante criterios de importancia de variables que el conteo de microaneurismas desempeña el papel más relevante en la discriminación de la enfermedad.

3. **Relación entre Exudados:** Al igual que con los microaneurismas, se observan clústeres de alta correlación entre los niveles de detección de exudados, particularmente entre `exudate2`, `exudate3` y `exudate4` (valores entre 0,92 y 1,00). Su correlación con la variable `Class` es positiva pero moderada (máximo de 0,18 en `exudate7` y `exudate8`), indicando que, aunque son indicadores de RD, su peso diagnóstico individual en este dataset es menor al de los microaneurismas, ya que dentro de este grupo existe `ma1` con 0,29, siendo un mejor indicador para indicar que el paciente pueda estar enfermo.

4. **Independencia de Rasgos Anatómicos:** Atributos como `macula_opticdisc_distance` (0,01) y `optic_disc_diameter` (-0,03) muestran una correlación prácticamente nula con la presencia de la enfermedad en este conjunto de datos. Esto sugiere que la patología se manifiesta principalmente a través de lesiones detectables (MA y exudados) antes de generar cambios anatómicos macroscópicos detectables por estos descriptores específicos. Por lo tanto, la anatomía del ojo es independiente de la patología.

5. **Correlación Negativa con AM/FM:** La correlación negativa observada entre el análisis AM/FM y los microaneurismas (valores entre -0,34 y -0,44) indica una relación inversa: a medida que aumenta la carga de lesiones, la regularidad de la

textura retinal disminuye. Debemos tener claro que los microaneurismas aparecen como «ruido» o manchas que interfieren con la textura suave. Al detectar este desorden, el valor de la señal AM/FM cae o baja. Podemos entonces indicar que el algoritmo tiene una doble verificación. Si el conteo sube (microaneurismas) y la calidad de la textura baja (correlación negativa), el sistema está 100 % seguro de que hay una patología.

4.5.2. Conclusión del Análisis de Correlación

El mapa de calor confirma que los microaneurismas son los predictores lineales más relevantes para el diagnóstico, seguidos por los exudados con menor peso. Las variables anatómicas no aportan información diagnóstica en este dataset, es decir, la anatomía del disco óptico no interfiere a la hora de decidir si un paciente está enfermo. La alta colinealidad interna entre variables MA y entre variables de exudados justifica usar solo representantes de cada grupo en modelos futuros para evitar redundancia.

4.6. Comparación de Grupos (Prueba Mann-Whitney U)

Habiendo establecido en la sección anterior que las variables de microaneurismas (`ma1` a `ma6`) no siguen una distribución normal, la comparación entre grupos requiere necesariamente un enfoque no paramétrico. La pregunta clínica central de este estudio es si el recuento de microaneurismas distingue de manera estadísticamente confiable a los pacientes con retinopatía diabética (Clase 1) de aquellos sin la enfermedad (Clase 0). Responder esta pregunta mediante una prueba paramétrica clásica como la t de Student habría invalidado los resultados, dado que el supuesto de normalidad fue rechazado con p-valores del orden de 10^{-20} en todos los niveles.

Por esta razón, se seleccionó la **prueba de Mann-Whitney U** (Mann & Whitney, 1947), cuya hipótesis operativa no requiere normalidad y compara las distribuciones de ambos grupos evaluando si los valores de un grupo tienden sistemáticamente a ser mayores que los del otro. Esta propiedad la hace especialmente adecuada para datos biomédicos con distribuciones asimétricas, donde las medianas son más representativas

de la tendencia central que las medias.

4.6.1. Planteamiento de Hipótesis

- **Hipótesis Nula** (H_0): La distribución del recuento de microaneurismas es idéntica en pacientes sanos (Clase 0) y en pacientes con retinopatía diabética (Clase 1); cualquier diferencia observada es atribuible al azar.
- **Hipótesis Alternativa** (H_1): Existe una diferencia sistemática y estadísticamente significativa en la distribución de microaneurismas entre ambos grupos, siendo consistentemente más elevada en la Clase 1.

4.6.2. Resultados de la Prueba

Los estadísticos obtenidos mediante la librería `scipy.stats` (Virtanen et al., 2020) se detallan en la siguiente tabla:

Tabla 5: Resultados de la prueba Mann-Whitney U para microaneurismas.

Variable	U_statistic	p_value	Significativo
ma1	111208	$1,25 \times 10^{-21}$	Sí
ma2	116076	$3,67 \times 10^{-18}$	Sí
ma3	121532	$1,17 \times 10^{-14}$	Sí
ma4	127750	$3,73 \times 10^{-11}$	Sí
ma5	133506	$2,25 \times 10^{-08}$	Sí
ma6	139938	$8,62 \times 10^{-06}$	Sí

4.6.3. Interpretación de los Hallazgos

1. **Rechazo unánime de la hipótesis nula:** En todos los niveles de confianza (α de 0,5 a 1,0), los p-valores se ubican varios órdenes de magnitud por debajo del umbral convencional de 0,05. El valor más conservador, obtenido en **ma6** ($8,62 \times 10^{-6}$), es en sí mismo una evidencia contundente de diferencia real entre grupos.

Este resultado descarta enfáticamente que las diferencias observadas se deban a fluctuaciones muestrales.

2. **Gradiente de significancia y su interpretación clínica:** La significancia estadística disminuye progresivamente desde **ma1** hasta **ma6**, en correspondencia directa con el aumento del umbral de confianza en la detección de lesiones. **ma1** registra el p-valor más bajo ($1,25 \times 10^{-21}$), lo que indica que incluso los microaneurismas detectados con sensibilidad moderada ($\alpha = 0,5$) son potentes discriminadores de la enfermedad. Desde el punto de vista clínico, esto sugiere que no se requiere un umbral de detección estricto para obtener una señal diagnóstica significativa: la presencia temprana de lesiones ya distingue de forma sólida a los pacientes afectados. Conforme aumenta el umbral (α), el detector retiene únicamente las lesiones más evidentes, reduciendo el contraste entre grupos y, con ello, la potencia estadística de la comparación. Este patrón apoya el uso de **ma1** como variable primaria en el modelamiento posterior.
3. **Significancia estadística versus magnitud del efecto:** Si bien los p-valores obtenidos son extremadamente pequeños, su interpretación debe realizarse con cautela. La significancia estadística es sensible al tamaño muestral y no cuantifica por sí sola la magnitud de la diferencia entre grupos. Para este análisis, una limitación reconocida es la ausencia de una medida de tamaño de efecto, como la correlación de rango biserial ($r_{biserial}$) o el estadístico $\hat{A}_{12}$ de Vargha-Delaney (Vargha & Delaney, 2000), que permitirían determinar qué fracción de los casos de Clase 1 supera a los de Clase 0. Su incorporación en estudios futuros fortalecería la relevancia práctica y clínica de estos resultados.
4. **Coherencia con evidencia previa:** Los hallazgos son consistentes con lo reportado por Casanova et al. (2014), quienes identifican el conteo de microaneurismas como la variable de mayor importancia diagnóstica entre todos los descriptores extraídos de imágenes de fondo de ojo, consolidando a este biomarcador como el indicador más robusto de la patología en este dataset.

4.7. Homogeneidad de Varianzas (Test de Levene)

La evaluación de la homogeneidad de varianzas se realizó mediante el **Test de Levene** con un propósito estrictamente exploratorio: caracterizar la estructura de variabilidad intragrupal y comprender la heterogeneidad clínica de los grupos comparados. Es importante aclarar que este análisis no constituye un requisito técnico para la prueba de Mann-Whitney U, ya que ésta es robusta frente a la heterocedasticidad y no presupone igualdad de varianzas. El valor del test de Levene en este contexto radica en su capacidad para revelar si ambos grupos exhiben no solo medianas distintas, sino también grados de dispersión cualitativamente diferentes, lo cual tiene implicaciones clínicas directas.

4.7.1. Planteamiento de Hipótesis

- **Hipótesis Nula** (H_0): Las varianzas del recuento de microaneurismas son iguales entre pacientes sanos (Clase 0) y con retinopatía (Clase 1) (homocedasticidad).
- **Hipótesis Alternativa** (H_1): Las varianzas difieren significativamente entre ambos grupos (heterocedasticidad).

4.7.2. Resultados

Tabla 6: Resultados del Test de Levene para microaneurismas.

Variable	Estadístico	p_value	Homocedasticidad
ma1	35.9975	$2,64 \times 10^{-9}$	No (varianzas distintas)
ma2	23.6750	$1,30 \times 10^{-6}$	No (varianzas distintas)
ma3	16.6036	$4,92 \times 10^{-5}$	No (varianzas distintas)
ma4	10.6155	$1,15 \times 10^{-3}$	No (varianzas distintas)
ma5	5.9695	$1,47 \times 10^{-2}$	No (varianzas distintas)
ma6	4.5424	$3,33 \times 10^{-2}$	No (varianzas distintas)

4.7.3. Interpretación

En todas las variables se rechaza la hipótesis nula ($p < 0,05$), confirmando que los grupos difieren no solo en sus medianas, sino también en su dispersión interna. La heterocedasticidad es más pronunciada en **ma1** (estadístico = 35,99) y se atenúa gradualmente hacia **ma6** (estadístico = 4,54), aunque sin alcanzar la homocedasticidad en ningún nivel.

Desde una perspectiva clínica, este hallazgo tiene una interpretación directa y relevante: la Clase 0 (pacientes sanos) exhibe un recuento de microaneurismas relativamente estable y predecible, mientras que la Clase 1 (pacientes con RD) muestra una variabilidad considerablemente mayor. Esta heterogeneidad refleja la naturaleza propia de la enfermedad: la retinopatía diabética no es un estado uniforme, sino un espectro que abarca desde etapas incipientes con escasas lesiones hasta formas proliferativas con compromiso extenso. En consecuencia, la dispersión elevada en el grupo afectado no constituye ruido estadístico, sino una manifestación auténtica de la variedad de estadios clínicos presentes en la muestra.

Adicionalmente, el patrón decreciente del estadístico de Levene a medida que aumenta el umbral de confianza (α) es coherente con el argumento expuesto en las secciones previas: los detectores de mayor exigencia capturan únicamente lesiones altamente evidentes, reduciendo la separación entre grupos y homogeneizando relativamente las distribuciones. El gradiente observado entre **ma1** y **ma6** ilustra, por tanto, un continuo entre la máxima sensibilidad diagnóstica y la mayor especificidad del sistema de detección, siendo **ma1** el nivel en que las diferencias estructurales entre grupos son más pronunciadas en ambas dimensiones: tendencia central y dispersión.

4.8. Modelamiento mediante Regresión Logística

El objetivo de esta sección es construir un modelo de clasificación binaria que cuantifique la relación entre los descriptores clínicos y la probabilidad de presencia de retinopatía diabética. Se adoptó la **Regresión Logística** como modelo de referencia (*baseline*), por ser el método estándar para variables dependientes binarias y por ofrecer

coeficientes interpretables que permiten vincular directamente cada predictor con el diagnóstico. Su inclusión en este estudio no busca obtener el clasificador de mayor precisión posible —objetivo que requeriría métodos no lineales de mayor complejidad—, sino establecer un umbral de desempeño mínimo a partir del cual evaluar el aporte de enfoques más sofisticados.

4.8.1. Justificación de la Selección de Atributos

Para construir un modelo estadísticamente válido, se seleccionó un subconjunto representativo de cuatro variables: `ma1`, `exudate1`, `macula_opticdisc_distance` y `opticdisc_diameter`. Esta decisión responde a criterios metodológicos rigurosos y no a una simplificación arbitraria:

- **Control de la multicolinealidad:** El análisis de correlación previo evidenció colinealidad casi perfecta entre las variables `ma1`–`ma6` ($r \approx 1,00$) y entre los niveles de exudados. En modelos de regresión, la inclusión de predictores altamente correlacionados infla los errores estándar de los coeficientes, produciendo estimaciones inestables e invalidando las pruebas de significancia individuales. Dado que `ma1` concentra la mayor correlación con `Class` ($r = 0,29$) y el mayor poder discriminante según la prueba de Mann-Whitney U, se utilizó como representante canónico del grupo de microaneurismas. De forma análoga, `exudate1` representa la dimensión de los depósitos lipídicos.
- **Representación multidimensional:** El subconjunto seleccionado abarca las tres dimensiones diagnósticas del dataset: lesiones microvasculares (`ma1`), depósitos de lípidos (`exudate1`) y rasgos anatómicos estructurales (`macula_opticdisc_distance` y `opticdisc_diameter`). Su inclusión permite verificar empíricamente si las características geométricas del ojo aportan valor predictivo adicional más allá de las lesiones detectables, hipótesis que será evaluada mediante la significancia de sus coeficientes.
- **Parsimonia y relevancia clínica:** Siguiendo el principio de parsimonia estadística, se privilegió un modelo con pocos predictores pero bien justificados, en línea

con los hallazgos de Casanova et al. (2014), quienes priorizan los microaneurismas como el rasgo de mayor importancia para la discriminación automatizada de la enfermedad.

4.8.2. Evaluación Global y Bondad de Ajuste

El modelo fue evaluado sobre un conjunto de prueba del 20 % (231 instancias). El área bajo la curva ROC obtenida fue de **AUC = 0,65** y el pseudo- R^2 de McFadden alcanzó un valor de **0,087**.




Figura 3: Matriz de confusión y Curva ROC-AUC del modelo de regresión logística.

Un AUC de 0,65 debe interpretarse con precisión académica: supera al clasificador aleatorio ($AUC = 0,50$) y confirma que el modelo captura información diagnóstica real, pero se ubica muy por debajo de los estándares de utilidad clínica. En el contexto del cribado automatizado de retinopatía diabética, la literatura reporta valores de AUC superiores a 0,95 mediante métodos de aprendizaje automático no lineales (Casanova et al., 2014), lo que pone en perspectiva la limitación intrínseca del enfoque lineal. El pseudo- R^2 de 0,087 refuerza esta conclusión: el modelo logístico explica aproximadamente el 8,7 % de la varianza en la variable de diagnóstico, lo que indica que la relación entre los predictores seleccionados y la clase no es capturada adecuadamente mediante una función de decisión lineal. Estos resultados no constituyen un fracaso del análisis, sino una evidencia metodológicamente valiosa: la complejidad del problema de clasifi-

cación supera la capacidad representacional de un modelo lineal, señalando la dirección que debe tomar el desarrollo futuro.

4.8.3. Interpretación de los Coeficientes y Significancia

Al analizar los resultados individuales de la regresión, se extraen las siguientes conclusiones:

- **Significancia crítica de microaneurismas (ma1):** Con un p-valor de 0,000 y un coeficiente positivo de 0,0307, se confirma que cada unidad de incremento en el recuento de microaneurismas eleva significativamente la probabilidad estimada de diagnóstico positivo. Este resultado valida empíricamente la hipótesis central del estudio y es coherente con todas las pruebas inferenciales previas, posicionando a `ma1` como el biomarcador más robusto del dataset.
- **Impacto de exudados (exudate1):** La significancia estadística de esta variable (p-valor = 0,000) confirma que la presencia de depósitos de lípidos constituye un predictor primario independiente de la patología, aportando información diagnóstica complementaria a la de los microaneurismas.
- **Irrelevancia de rasgos anatómicos estructurales:** La distancia mácula-disco ($p = 0,632$) y el diámetro del disco óptico ($p = 0,330$) no alcanzaron significancia estadística. Este hallazgo es clínicamente coherente: la retinopatía diabética en estadios evaluables por imágenes de fondo de ojo se manifiesta principalmente a través de lesiones vasculares y exudados, mientras que los cambios estructurales macroscópicos del nervio óptico son característicos de otras patologías como el glaucoma.

4.8.4. Evaluación de Desempeño (Matriz de Confusión y ROC)

La capacidad de clasificación del modelo se evaluó mediante los resultados en el conjunto de prueba:

1. Matriz de Confusión:

- **Verdaderos Positivos (TP):** 79 pacientes con RD correctamente identificados.
- **Verdaderos Negativos (TN):** 58 pacientes sanos correctamente identificados.
- **Falsos Negativos (FN):** 49 casos de RD no detectados, resultando en una sensibilidad del 61,7 %.
- **Falsos Positivos (FP):** 45 casos sanos clasificados erróneamente, resultando en una especificidad del 56,3 %.

2. **Análisis crítico del desempeño clínico:** La sensibilidad del 61,7 % implica que el modelo no detecta aproximadamente 4 de cada 10 pacientes con RD, lo cual es inaceptable para un sistema de cribado clínico donde minimizar los falsos negativos es prioritario para evitar la progresión inadvertida de la enfermedad hacia la ceguera. La especificidad del 56,3 % agrava esta situación, ya que más de la mitad de los pacientes sanos recibirían una derivación innecesaria. Estas métricas evidencian que el modelo logístico, tal como está formulado, no alcanza el umbral de utilidad clínica y debe entenderse exclusivamente como un punto de partida cuantitativo para la comparación con modelos más complejos.

3. **Curva ROC-AUC:** El valor de 0,65 sitúa el desempeño del modelo en la categoría de “discriminación débil” según los criterios convencionales (Hosmer et al., 2013), confirmando que las cuatro variables seleccionadas, aunque estadísticamente significativas como predictores individuales, son insuficientes para sostener un clasificador de alta fidelidad bajo una arquitectura lineal. El valor de referencia de la literatura para sistemas de cribado automatizado de RD supera el AUC de 0,989 (Casanova et al., 2014), lo que cuantifica el margen de mejora que los métodos no lineales deben cubrir.

4.8.5. Validación de Residuos

Como complemento al análisis de desempeño, se examinó la distribución de los residuos del modelo, calculados como la diferencia entre la clase real y la probabilidad

predicha. Un modelo bien ajustado debería presentar residuos centrados en cero y sin sesgos sistemáticos.




Figura 4: Histograma de residuos del modelo de regresión logística con curva de densidad superpuesta.

La distribución exhibe las dos agrupaciones características de la clasificación logística binaria: una concentración en valores negativos (casos de Clase 0 a los que el modelo asigna alta probabilidad de RD) y una en valores positivos (casos de Clase 1 clasificados con baja probabilidad). La ausencia de normalidad en los residuos es un comportamiento esperado y válido en modelos de clasificación binaria, por lo que no constituye una violación de los supuestos del método. Sin embargo, la amplitud de ambas agrupaciones y su solapamiento reflejan visualmente el nivel de incertidumbre del modelo en la zona de decisión, coherente con el AUC de 0,65 obtenido.

5. Conclusiones

El análisis estadístico e inferencial realizado sobre el dataset **Diabetic Retinopathy Debrecen** permitió caracterizar la naturaleza distribucional de los biomarcadores de microaneurismas, validar la existencia de diferencias sistemáticas entre grupos y evaluar la capacidad predictiva de un modelo lineal de referencia. Los resultados obtenidos responden de manera coherente a la pregunta clínica central del estudio y establecen una base metodológica sólida para el desarrollo de clasificadores de mayor complejidad.

5.1. Síntesis de Hallazgos Principales

Se confirmó la **no normalidad** de todas las variables de microaneurismas mediante la prueba de Shapiro-Wilk, con p-valores del orden de 10^{-20} que justifican inequívocamente el uso de estadística no paramétrica en el análisis inferencial. Esta característica distribucional, junto con la asimetría positiva documentada, es clínicamente coherente: en una población que incluye tanto pacientes sanos como afectados, la mayoría de los individuos presentan recuentos bajos de lesiones, mientras que una minoría con enfermedad avanzada genera la cola derecha de la distribución.

La validación de valores atípicos mediante el método de Tukey reforzó esta interpretación: la práctica totalidad de los outliers identificados corresponde a la Clase 1, confirmando que los recuentos extremos de microaneurismas son manifestaciones clínicas genuinas de estadios severos de retinopatía diabética y no errores de medición. La única excepción (índice 14, Clase 0, **ma6**) es explicable por la naturaleza probabilística del sistema de detección al operar con umbral $\alpha = 1,0$.

5.2. Discusión de Resultados y Desempeño del Modelo

La prueba de **Mann-Whitney U** demostró diferencias estadísticamente significativas entre grupos en todos los niveles de confianza ($p < 0,05$ en todos los casos), siendo **ma1** la variable con mayor potencia discriminadora ($p = 1,25 \times 10^{-21}$). El gradiente de significancia observado desde **ma1** hasta **ma6** evidencia que los detectores de

menor umbral capturan la señal clínica más nítidamente, respaldando su uso prioritario en sistemas de cribado temprano. El **Test de Levene** añadió una dimensión clínica relevante a este análisis: los grupos difieren no solo en tendencia central, sino también en dispersión, lo que refleja la heterogeneidad inherente al espectro de severidad de la retinopatía diabética.

El modelo de **Regresión Logística**, concebido explícitamente como clasificador de referencia (*baseline*), confirmó la significancia individual de **ma1** y **exudate1** como predictores primarios ($p = 0,000$ en ambos casos), mientras que los rasgos anatómicos estructurales no mostraron aporte predictivo lineal. No obstante, el desempeño global del modelo evidenció limitaciones críticas: una sensibilidad del 61,7%, una especificidad del 56,3% y un AUC de 0,65. Estos valores confirman que, si bien los biomarcadores seleccionados contienen información diagnóstica real, la relación entre predictores y diagnóstico presenta una complejidad no lineal que no puede ser adecuadamente capturada mediante una función de decisión lineal. El pseudo- R^2 de McFadden de 0,087 cuantifica esta limitación: el modelo explica menos del 9% de la varianza en el diagnóstico, subrayando que el problema de clasificación involucra interacciones entre variables y patrones de alta dimensionalidad que escapan al alcance de la regresión logística estándar.

5.3. Limitaciones y Proyecciones Futuras

Las principales limitaciones de este análisis son de dos órdenes. En primer lugar, de naturaleza metodológica: la ausencia de medidas de tamaño de efecto en la comparación de grupos impide cuantificar la magnitud práctica de las diferencias detectadas más allá de su significancia estadística; su incorporación mediante métricas como la correlación de rango biserial o el estadístico $\hat{A}_{12}$ fortalecería la interpretabilidad clínica de los resultados. En segundo lugar, de naturaleza estructural: la alta colinealidad entre las variables MA ($r \approx 1,00$), aunque gestionada mediante la selección de **ma1** como representante del grupo, sugiere que el espacio de características podría beneficiarse de una reducción de dimensionalidad formal, como el Análisis de Componentes Principales (PCA), preservando la varianza diagnóstica con menor redundancia.

Como proyección futura, los resultados de este estudio señalan de forma inequívoca la necesidad de algoritmos de inteligencia computacional no lineales. Métodos como *Random Forests*, *Gradient Boosting* o redes neuronales convolucionales aplicadas directamente sobre imágenes de fondo de ojo están en capacidad de explotar la alta colinealidad detectada como información complementaria, modelar interacciones no lineales entre lesiones y rasgos anatómicos, y alcanzar los niveles de sensibilidad ($>90\%$) y AUC ($>0,95$) exigidos para sistemas de cribado automatizado con aplicabilidad clínica real, tal como documentan Casanova et al. (2014). El modelo logístico desarrollado en este trabajo proporciona el umbral de comparación cuantitativo indispensable para evaluar el beneficio marginal de esos enfoques más sofisticados.

Anexos

Referencias

- Antal, B., & Hajdu, A. (2014a). Diabetic Retinopathy Debrecen. <https://doi.org/10.24432/C5XP4P>
- Antal, B., & Hajdu, A. (2014b). An ensemble-based system for automatic screening of diabetic retinopathy. *Knowledge-Based Systems*. <https://doi.org/10.1016/j.knsys.2014.01.007>
- Casanova, R., Saldana, S., Chew, E. Y., Danis, R. P., Greven, C. M., & Ambrosius, W. T. (2014). Application of Random Forests Methods to Diabetic Retinopathy Classification Analyses. *PLoS ONE*, 9(6), e98587. <https://doi.org/10.1371/journal.pone.0098587>
- Harris, C. R., et al. (2020). Array programming with NumPy. *Nature*, 585, 357-362. <https://doi.org/10.1038/s41586-020-2649-2>
- Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3.^a ed.). John Wiley & Sons. <https://doi.org/10.1002/9781118548387>
- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90-95. <https://doi.org/10.1109/MCSE.2007.55>
- Kelly, M., Longjohn, C., & Nottingham, K. (2023). ucimlrepo: Python wrapper for the UCI Machine Learning Repository. <https://github.com/uci-ml-repo/ucimlrepo>
- Mann, H. B., & Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1), 50-60. <https://doi.org/10.1214/aoms/1177730491>
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Team, T. P. D. (2024, febrero). *pandas-dev/pandas: Pandas* (Ver. latest). Zenodo. <https://doi.org/10.5281/zenodo.3509134>
- Vargha, A., & Delaney, H. D. (2000). A critique and improvement of the CL common language effect size statistics of McGraw and Wong. *Journal of Educational and Behavioral Statistics*, 25(2), 101-132. <https://doi.org/10.3102/10769986025002101>

- Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, 17, 261-272. <https://doi.org/10.1038/s41592-019-0686-2>
- Waskom, M. L. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>
- Wilkinson, C. P., Ferris III, F. L., Klein, R. E., Lee, P. P., Agardh, C. D., Davis, M., Dills, D., Kampik, A., Pararajasegaram, R., & Verdaguer, J. T. (2003). Proposed international clinical diabetic retinopathy and diabetic macular edema disease severity scales. *Ophthalmology*, 110(9), 1677-1682. [https://doi.org/10.1016/S0161-6420\(03\)00475-5](https://doi.org/10.1016/S0161-6420(03)00475-5)