

UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
Departamento de Ingeniería Informática



Laboratorio 1
Diabetic Retinopathy Debrecen

Integrantes: Gonzalo Ahumada
Daniel Muñoz
Asignatura: Inteligencia Computacional
Profesor: Max Chacón
Ayudante: Sebastián Chávez

4 de mayo de 2026

Tabla de contenidos

1. Introducción	1
1.1. Contextualización y Antecedentes	1
1.2. Objetivos del Laboratorio	2
1.3. Formulación de Hipótesis	3
2. Descripción del Problema	3
2.1. Descripción de la Base de Datos (Diabetic Retinopathy Debrecen) . . .	3
2.2. Descripción de Clases y Variables	4
2.2.1. Variables de Calidad y Pre-procesamiento	4
2.2.2. Detección de Lesiones y Niveles de Confianza	4
2.2.3. Descriptores Anatómicos	5
2.2.4. Variable de Clase (Objetivo)	5
3. Marco Teórico	6
3.1. Retinopatía Diabética e Importancia Médica de las Lesiones	6
3.2. Fundamentos de Estadística Descriptiva y Forma de Distribución . . .	7
3.3. Fundamentos de Estadística Inferencial y Pruebas de Hipótesis	9
4. Análisis Estadístico e Inferencial	12
4.1. Resumen Estadístico Descriptivo	12
4.2. Análisis de la Forma de la Distribución (Asimetría y Curtosis)	12
4.3. Validación de Normalidad (Prueba de Shapiro-Wilk)	12
4.4. Detección de Valores Atípicos (Outliers)	14
4.4.1. Metodología de Tukey	14
4.4.2. Resultados de la Detección	15
4.4.3. Visualización mediante Boxplots por Clase	16
4.5. Análisis de Correlación y Visualización (Heatmap)	17
4.5.1. Interpretación del Mapa de Calor	17
4.5.2. Conclusión del Análisis de Correlación	19
4.6. Comparación de Grupos (Prueba Mann-Whitney U)	19

4.6.1.	Planteamiento de Hipótesis	19
4.6.2.	Resultados de la Prueba	19
4.6.3.	Interpretación de los Hallazgos	20
4.7.	Homogeneidad de Varianzas (Test de Levene)	21
4.7.1.	Planteamiento de Hipótesis	21
4.7.2.	Resultados	21
4.7.3.	Interpretación	22
4.8.	Modelamiento mediante Regresión Logística	22
4.8.1.	Justificación de la Selección de Atributos	22
4.8.2.	Evaluación Global y Bondad de Ajuste	23
4.8.3.	Interpretación de los Coeficientes y Significancia	23
4.8.4.	Evaluación de Desempeño (Matriz de Confusión y ROC)	24
4.8.5.	Validación de Residuos	25
5.	Conclusiones	27
5.1.	Síntesis de Hallazgos Principales	27
5.2.	Discusión de Resultados y Desempeño del Modelo	27
5.3.	Limitaciones y Proyecciones Futuras	27
	Bibliografía	30

1. Introducción

1.1. Contextualización y Antecedentes

Las personas con diabetes pueden tener una enfermedad ocular llamada retinopatía diabética. Esta enfermedad ocurre porque los niveles altos de azúcar en la sangre causan daño a los vasos sanguíneos en la retina. Estos vasos sanguíneos pueden hincharse y tener fugas de líquido. También pueden cerrarse e impedir que la sangre fluya. A veces, se generan nuevos vasos sanguíneos anormales en la retina. Todos estos cambios pueden hacerle perder la visión.

La retinopatía diabética (RD) representa una de las principales causas de pérdida de visión a nivel mundial y es considerada una “enfermedad silenciosa”, ya que a menudo progresa sin síntomas visibles hasta etapas avanzadas en que las posibilidades de recuperación visual son reducidas (Casanova et al., 2014).

Puede tener retinopatía diabética y no saberlo. Esto se debe a que generalmente no presenta síntomas en sus etapas tempranas. A medida que empeora, podemos notar los siguientes síntomas: visión borrosa, visión que cambia de borrosa a clara, ver áreas en blanco o oscuras en el campo de visión, visión nocturna deficiente, notar que los colores se ven atenuados o apagados y perder la visión.

La detección temprana es fundamental para permitir intervenciones terapéuticas eficaces, pero los métodos tradicionales de examen clínico enfrentan barreras como que una mismo examen de retina pueda ser analizado por diferentes médicos llegando a diferentes conclusiones y la falta de especialistas en zonas rurales, lo que imposibilita el acceso a estas personas a un diagnóstico temprano de la enfermedad (Casanova et al., 2014). Esto ha impulsado el desarrollo de sistemas computacionales que se encargan de analizar imágenes de retina de manera automática, entregando un diagnóstico objetivo y que a la vez le sirve al sistema para entrenar los modelos (Antal & Hajdu, 2014b).

Para el desarrollo de este laboratorio, se analiza el conjunto de datos *Diabetic Retinopathy Debrecen*, el cual consiste en 1.151 fotografías de retina de diferentes pacientes y 19 atributos que fueron extraídos de todas esas fotografías. Los datos de estos atributos se obtuvieron gracias al conjunto de imágenes Messidor, que es una base

de datos de imagenes retinales de hospitales franceces. (Antal & Hajdu, 2014a). Estos atributos capturan características críticas para el diagnóstico, incluyendo el conteo de microaneurismas detectados con distintos grados de confianza del algoritmo, la cantidad normalizada de exudados (depósitos de grasa que se acumulan en la retina cuando los vasos sanguíneos presentan daño) y descriptores anatómicos como la distancia entre la mácula y el disco óptico (Antal & Hajdu, 2014a). La libros científicos sugieren que el conteo de microaneurismas es el factor de mayor peso para discriminar la presencia de la enfermedad en modelos computacionales (Casanova et al., 2014), es por esto que existen 6 variables (ma1 a ma6) para analizar lo que puede llegar a ser un microaneurisma, estos niveles de confianza se conocen como confidence threshold o threshold de confianza.

1.2. Objetivos del Laboratorio

General: Estudiar e interpretar los datos del dataset seleccionado para obtener información objetiva sobre como poder detectar la Retinopatía Diabética en un paciente, mas aun sabiendo que es un diagnostico dificil sino se analizan imagenes retinales por sistemas computacionales. Ademas de lo anterior la información entregada por el dataset permite descubrir cuales atributos son mas importantes para el diagnostico objetivo de esta enfermedad. Por ultimo, este analisis permite conscientizar sobre una de las enfermedades con menos oportunidad de descubrimiento en etapas iniciales, lo cual nos hace reflexionar sobre lo importante que es contar con ayuda tecnologica para el bienestar y salud de pacientes que incluso ya cuentan con una enfermedad de base como lo es la diabetes. (Antal & Hajdu, 2014a) .

Específicos:

1. Realizar un análisis estadístico descriptivo para resumir las características fundamentales del conjunto de datos.
2. Aplicar técnicas de estadística inferencial, incluyendo pruebas de normalidad y de hipótesis, para obtener conclusiones de los resultados obtenidos.

3. Identificar qué variables presentan diferencias significativas entre pacientes sanos y aquellos con signos de la patología.

1.3. Formulación de Hipótesis

Basándose en la literatura científica (Casanova et al., 2014), se postula que las variables relacionadas con el conteo de microaneurismas (`ma1` a `ma6`) y la detección de exudados (`exudate1` a `exudate8`) constituyen los principales marcadores clínicos para discriminar entre pacientes sanos y pacientes con retinopatía diabética, superando incluso a las variables anatómicas estructurales como el diámetro del disco óptico, la distancia mácula-disco, entre otras.

2. Descripción del Problema

2.1. Descripción de la Base de Datos (Diabetic Retinopathy Debrecen)

Este conjunto de datos contiene atributos extraídos del set de imágenes **Messidor** (Antal & Hajdu, 2014a). Messidor es una base de imágenes retinales desarrollada por hospitales universitarios de Francia, ampliamente utilizada como referencia en investigación de diagnóstico automatizado de retinopatía diabética. Consta de 1.151 retinografías y 19 atributos que representan lesiones detectadas, rasgos anatómicos (distancia mácula-disco óptico) y descriptores de nivel de imagen (Antal & Hajdu, 2014a). El dataset es de naturaleza multivariada, debido a que contamos con diferentes tipos de variables con las cuales podamos decidir si el paciente está o no enfermo. Este conjunto de datos nos indica principalmente si existe o no enfermedad, es decir, la clasificación y análisis de variables da como resultado: (clase 1 para signos de RD y clase 0 para ausencia) (Antal & Hajdu, 2014a).

2.2. Descripción de Clases y Variables

A continuación, se detalla la naturaleza y relevancia de cada una de las 19 variables del conjunto de datos:

2.2.1. Variables de Calidad y Pre-procesamiento

- **quality**: Indicador binario de la calidad de la retinografía (0 = calidad insuficiente para el diagnóstico, 1 = calidad suficiente).
- **pre_screening**: Indicador binario de una revisión preliminar automática de la imagen, donde el valor 1 señala la detección de una anomalía retiniana grave que justifica un análisis más profundo, y 0 indica ausencia de señales de alerta.
- **am_fm_classification**: Resultado binario de un análisis matemático para detectar si hay estructuras que “rompen” el patrón normal de una retina sana. Si la señal AM-FM detecta muchas variaciones bruscas, es un indicador fuerte de que hay patología (lesiones).

2.2.2. Detección de Lesiones y Niveles de Confianza

- **ma1 a ma6** (Microaneurismas): Representan el conteo de microaneurismas (MA) detectados mediante algoritmos de procesamiento de imágenes. La literatura identifica a los microaneurismas como el factor de mayor importancia para discriminar la presencia de la enfermedad. Podemos indicar aquí que un microaneurisma es un pequeño punto rojo, y que estas variables son el conteo físico de esas lesiones.
 - **Nota técnica sobre los niveles de confianza**: La distinción entre estas seis variables radica en el nivel de confianza (α) del algoritmo, que escala desde $\alpha = 0,5$ (**ma1**) hasta $\alpha = 1,0$ (**ma6**). Un nivel de confianza más elevado indica criterios de detección más estrictos, lo que reduce la probabilidad de falsos positivos pero incrementa el riesgo de omitir lesiones reales y sutiles.
- **exudate1 a exudate8**: Representan la presencia de exudados (principalmente depósitos de lípidos y proteínas). A diferencia de los microaneurismas, estos valores

no son conteos simples, sino que están normalizados: Se divide el número de lesiones detectadas por el diámetro de la Región de Interés (ROI). Esto permite identificar cuanta densidad de exudados existe en la retina, independiente de cuanto cerca o lejos se tomó la imagen.

- **Nota sobre calidad del dataset:** El análisis exploratorio reveló que las columnas `exudate3` y `exudate4` son **idénticas** en todos los registros del dataset. Esta redundancia es una característica del conjunto de datos original publicado en UCI y es propio del diseño del algoritmo original y debe considerarse en futuros análisis de reducción de variables, para no dar más peso a una variable que contiene el mismo dato.

2.2.3. Descriptores Anatómicos

- `euclidean_distance`: Mide qué tan lejos está el centro del ojo del nervio óptico. Es vital para localizar la fovea (donde vemos con detalle).
- `optic_disc_diameter`: Medida del diámetro del disco óptico.

2.2.4. Variable de Clase (Objetivo)

Class: Indica el estado del diagnóstico del paciente.

- 1: Indica que la imagen presenta signos de retinopatía diabética. Este valor agrupa los grados 1, 2 y 3 de severidad de la base Messidor, que van desde la presencia de microaneurismas leves hasta hemorragias y formación de nuevos vasos sanguíneos. En este punto se hace una simplificación de la información de los grados de severidad. Importando solo que el paciente presenta signos de la enfermedad.
- 0: Corresponde al grado 0 de Messidor, es decir, ausencia total de lesiones retinales detectables.

3. Marco Teórico

3.1. Retinopatía Diabética e Importancia Médica de las Lesiones

La retinopatía diabética (RD) es una de las principales causas de ceguera en el mundo y se caracteriza por ser una “enfermedad silenciosa” que progresa sin síntomas hasta etapas críticas (Casanova et al., 2014).

Ya por el año 2003 el estudio de la retinopatía diabética hacia patente que esta enfermedad no se diagnostica por cambios de nervio optico, sino que por una serie de lesiones jerarquicas: primero aparecen los microaneurismas, luego las hemorragias y por ultimo los exudados. (Wilkinson et al., 2003). En este punto entendemos la riqueza en la información proporcionada por el dataset utilizado.

Importante recalcar que gracias al procesamiento digital de imágenes retinales y a los modelos de aprendizaje automatico es que podemos llegar a saber que partes del ojo delatan esta enfermedad y tambien que tan avanzada esta.

Existen dos indicadores clave para clasificar a un paciente como sano o enfermo: los microaneurismas y los exudados.

- **Microaneurismas (MA):** Son las lesiones clínicas más tempranas de la RD. Consisten en pequeñas dilataciones en las paredes de los capilares retinales, causadas por el debilitamiento estructural provocado por niveles elevados de glucosa en la sangre. En imágenes de fondo de ojo (retinografía) se visualizan como puntos rojos diminutos y circulares con bordes bien definidos, es interesante indicar que el contraste frente al fondo anaranjado de la retina permite su identificación mediante filtros morfológicos (Antal & Hajdu, 2014b). Su conteo es el principal indicador de la etapa inicial de la enfermedad y el factor más relevante para discriminar computacionalmente la presencia de RD (Casanova et al., 2014).
- **Exudados:** Depósitos que aparecen cuando los vasos dañados filtran fluidos hacia el tejido retinal, indicando avance de la enfermedad hacia etapas moderadas o severas. En el análisis de datos, el área de los exudados se normaliza según el

diámetro de la Región de Interés (ROI) para compensar variaciones en el tamaño de las imágenes (Antal & Hajdu, 2014a). Podemos encontrar dos tipos:

- **Exudados duros:** Son depósitos de lípidos (grasas) y proteínas que se filtran desde el torrente sanguíneo hacia la retina. Se presentan como manchas pequeñas, brillantes y de tono amarillento.
- **Exudados blandos (manchas algodonosas):** Áreas de infarto (isquemia) donde el tejido nervioso muere por falta de oxígeno. Podemos identificarlas como manchas blancas más grandes con bordes difusos, indicativas de un avance en la enfermedad más severo.

Nota metodológica: La distinción clínica entre exudados duros y blandos se incluye en este trabajo con fines estrictamente informativos. Para efectos del análisis computacional y el procesamiento del dataset, se utiliza el bloque consolidado de variables que comprende desde `exudate1` hasta `exudate8`, las cuales capturan la densidad total de estas lesiones sin realizar una separación explícita en la clasificación del conjunto de datos.

3.2. Fundamentos de Estadística Descriptiva y Forma de Distribución

En estadística descriptiva buscamos indicadores que sean claves para comprender el comportamiento de las variables del conjunto de datos. En este análisis se responden preguntas como ¿dónde están concentrados los datos? ¿qué tan dispersos están? ¿hay valores extremos?

“Este análisis descriptivo permitirá confirmar si la distribución de los microaneurismas y exudados presenta una variabilidad significativa entre pacientes sanos y enfermos, validando su importancia como indicadores diagnósticos”

- **Medidas de tendencia central y dispersión:** Parametros basicos que nos permiten comprender que tan variados son los datos de nuestro conjunto, que tan diferentes son entre si, este analisis nos permite descubrir patrones de enfermedad.

Media aritmética: Es el promedio tradicional. Nos da una idea del valor "típico" de la variable sumando todos los casos y dividiendo por el total.

Mediana: Es el valor central cuando ordenamos los datos de menor a mayor. A diferencia de la media, es una medida robusta, lo que significa que no se ve afectada por valores extremadamente altos o bajos que no permitirían representar el comportamiento general de los datos.

Desviación estándar: Nos indica qué tan diferentes son los datos respecto al promedio. Una desviación alta significa que los datos están muy dispersos, que pueden existir valores atípicos con respecto al promedio; una baja, que están muy agrupados cerca del centro (promedio), valores que se asemejen más. Respondemos a la pregunta: ¿Qué tan diferentes son los pacientes entre sí respecto al promedio?

- **Forma de la distribución:** No basta con saber el centro; hay que saber cómo se “dibuja” el conjunto de datos.

Asimetría (*Skewness*): Nos dice si los datos se inclinan hacia un lado. Nos indica si la mayoría de los pacientes tienen valores bajos o altos de una lesión. Se responde a la pregunta: ¿Hacia dónde se inclina la balanza de pacientes? (Sanos vs. Graves).

Curtois: Esta medición nos sirve para encontrar las sorpresas en el conjunto de datos, como por ejemplo, si hay muchos pacientes con valores similares (alta curtois) o concentración de datos, inferimos entonces que la mayoría de los pacientes tienen valores de la variable similares o iguales, pero hay una probabilidad real de encontrar casos con valores que salen de lo común y se van a los extremos. Es una medición que nos invita a fijarnos en los datos extremos para que podamos identificarlos y que estos no afecten nuestros cálculos. Podemos encontrar donde están concentrados nuestros datos y también podemos saber si estos casos extremos son raros o son comunes dependiendo si el curtois es alto o bajo.

- **Detección de valores atípicos (*Outliers*):** ¿Qué es un outlier? Es un valor que se aleja tanto del resto que puede parecer no pertenecer al mismo grupo o

conjunto de datos. Una vez que la asimetría y la curtosis nos advierten que existen datos extremos, utilizamos el Método de Tukey para identificarlos con precisión.

¿Por qué importa detectarlos? Porque pueden distorsionar el análisis. Podríamos obtener el promedio de un conjunto de datos y no representar la realidad del mismo al considerar datos que salen de lo común y son poco representativos con respecto al conjunto general.

¿Qué es el método de Tukey?

Es la técnica más usada para detectar outliers de forma objetiva. Funciona de la siguiente manera:

1. Toma el 25 % inferior de los datos ($Q1$) y el 75 % superior ($Q3$).
2. Calcula la distancia entre ellos: $IQR = Q3 - Q1$.
3. Define un límite inferior: $Q1 - 1,5 \times IQR$.
4. Define un límite superior: $Q3 + 1,5 \times IQR$.
5. Todo lo que queda fuera de esos límites es un outlier.

3.3. Fundamentos de Estadística Inferencial y Pruebas de Hipótesis

Mientras que el análisis descriptivo solo describe lo que vemos, la inferencial va más allá — te permite sacar conclusiones y tomar decisiones basadas en los datos. La pregunta clave es: ¿lo que observo en mi muestra es real o es producto de la suerte?

Por ejemplo: veo que los pacientes enfermos tienen más microaneurismas que los sanos. Pero ¿esa diferencia es real o simplemente mi elección al seleccionar los pacientes del estudio no fue la mejor?

Las pruebas de hipótesis responden esa pregunta matemáticamente.

Entre las pruebas de hipótesis que se utilizan en este análisis se encuentran:

- **Prueba de normalidad (Shapiro-Wilk):**

Antes de aplicar cualquier prueba estadística, necesitas saber cómo se distribuyen nuestros datos — si siguen una distribución normal o no.

¿Por qué importa? Porque muchas pruebas estadísticas asumen que los datos son normales. Si no lo son, debemos usar pruebas distintas.

Shapiro-Wilk responde: ¿mis datos se comportan como una distribución normal?

Para responder la pregunta anterior es que tenemos el p-valor, una medida que nos permite decidir si rechazamos o no la hipótesis de normalidad y su límite es 0.05.

- Si $p\text{-valor} < 0,05 \rightarrow$ No son normales $\rightarrow$ usas pruebas no paramétricas (Pruebas más robustas).
- Si $p\text{-valor} > 0,05 \rightarrow$ Podrían ser normales $\rightarrow$ puedes usar pruebas paramétricas.

■ Comparación de grupos (prueba Mann-Whitney U):

Una vez que sabemos que los datos no son normales, necesitamos una prueba que compare dos grupos sin asumir normalidad. Es la herramienta que decide si hay una diferencia real entre los sanos y los enfermos.

Mann-Whitney U responde: ¿la distribución de esta variable es significativamente distinta entre pacientes sanos y enfermos?

- Si $p\text{-valor} < 0,05 \rightarrow$ Sí hay diferencia real entre los grupos.
- Si $p\text{-valor} > 0,05 \rightarrow$ No hay evidencia de diferencia.

■ Homocedasticidad (Test de Levene):

Se utiliza para evaluar la igualdad de varianzas entre diferentes grupos, en este caso grupo de pacientes sanos y enfermos.

Homocedasticidad es una palabra técnica que significa simplemente: ¿las varianzas de los dos grupos son iguales?

La varianza mide qué tan dispersos están los datos. Si los pacientes sanos tienen todos valores similares de microaneurismas pero los enfermos tienen valores muy dispersos, las varianzas son distintas — hay heterocedasticidad.

Levene responde: ¿la dispersión de esta variable es igual en ambos grupos?

Sirve para entender cómo se comporta la enfermedad. Si los enfermos tienen una varianza mucho más alta que los sanos, confirmas que la retinopatía afecta a cada persona de forma muy distinta (mucha variabilidad), mientras que los sanos son un grupo muy uniforme.

- Si $p\text{-valor} < 0,05 \rightarrow$ Las varianzas son distintas.
- Si $p\text{-valor} > 0,05 \rightarrow$ Las varianzas son iguales.

4. Análisis Estadístico e Inferencial

En esta sección se presentan los resultados del análisis de los 19 atributos del dataset **Diabetic Retinopathy Debrecen**. Para el desarrollo técnico se emplearon las bibliotecas *Pandas* (Team, 2024) para el manejo y estadística descriptiva de los datos, *SciPy* (`scipy.stats`) (Virtanen et al., 2020) para las pruebas estadísticas inferenciales, y *ucimlrepo* (Kelly et al., 2023) para la importación directa del dataset desde el repositorio UCI Machine Learning.

4.1. Resumen Estadístico Descriptivo

4.2. Análisis de la Forma de la Distribución (Asimetría y Curtosis)

Para las variables críticas de microaneurismas (**ma1** a **ma6**), identificadas en la literatura (Casanova et al., 2014) como los predictores más importantes para la detección de la RD, se evaluó su asimetría y curtosis:

Todas las variables de MA presentan una asimetría positiva, lo que indica que la distribución tiene una cola alargada hacia la derecha. Esto es coherente con un dataset médico donde muchos pacientes tienen pocos signos de lesión y una minoría presenta conteos elevados.

4.3. Validación de Normalidad (Prueba de Shapiro-Wilk)

Para formalizar la observación de la forma, se aplicó el test de **Shapiro-Wilk** bajo la hipótesis nula (H_0) de que los datos siguen una distribución normal:

Dado que en todos los casos el **p-valor** $< 0,05$, se rechaza la hipótesis nula. Esto confirma matemáticamente que los conteos de microaneurismas no se distribuyen de forma normal, lo cual condiciona el uso de pruebas no paramétricas para las comparaciones de grupos posteriores.

Tabla 1: Tabla de estadísticos descriptivos, los nombres y siglas están en inglés.

Variable	count	mean	std	min	max
quality	1151	0.996525	0.0588742	0	1
pre_screening	1151	0.918332	0.273977	0	1
ma1	1151	38.4283	25.6209	1	151
ma2	1151	36.9096	24.1056	1	132
ma3	1151	35.1407	22.8054	1	120
ma4	1151	32.2971	21.1148	1	105
ma5	1151	28.7472	19.5092	1	97
ma6	1151	21.1512	15.1016	1	89
exudate1	1151	64.0967	58.4853	0.349274	403.939
exudate2	1151	23.088	21.6027	0	167.131
exudate3	1151	8.70461	11.5676	0	106.07
exudate4	1151	8.70461	11.5676	0	106.07
exudate5	1151	0.560738	2.48411	0	51.4232
exudate6	1151	0.21229	1.05713	0	20.0986
exudate7	1151	0.0856741	0.398717	0	5.9378
exudate8	1151	0.0372251	0.178959	0	3.08675
macula_opticdisc_distance	1151	0.523212	0.0280554	0.367762	0.592217
opticdisc_diameter	1151	0.108431	0.0179448	0.057906	0.219199
am_fm_classification	1151	0.336229	0.472624	0	1

Tabla 2: Tabla de asimetría y curtosis para los microaneurismas.

Variable	Asimetría (skew)	Curtosis
ma1	0.743916	0.333756
ma2	0.62517	-0.0999926
ma3	0.532673	-0.468193
ma4	0.498474	-0.673164
ma5	0.533248	-0.692618
ma6	0.722384	-0.102349

Tabla 3: Tabla de validación de normalidad para los microaneurismas.

Variable	W	p-value	Distribución
ma1	0.945107	$2,94 \times 10^{-20}$	No Normal
ma2	0.950456	$3,02 \times 10^{-19}$	No Normal
ma3	0.950985	$3,84 \times 10^{-19}$	No Normal
ma4	0.947417	$7,86 \times 10^{-20}$	No Normal
ma5	0.938654	$2,18 \times 10^{-21}$	No Normal
ma6	0.929734	$8,23 \times 10^{-23}$	No Normal

4.4. Detección de Valores Atípicos (Outliers)

Para garantizar la robustez del análisis y comprender la variabilidad extrema en los datos, se realizó la detección de valores atípicos mediante el **método de Tukey**. Esta técnica es preferida en estudios clínicos debido a que utiliza medidas de posición no sensibles a los extremos, permitiendo identificar observaciones que se desvían significativamente del comportamiento central del grupo.

4.4.1. Metodología de Tukey

La identificación se basó en el cálculo del Rango Intercuartílico ($IQR = Q_3 - Q_1$), estableciendo los siguientes límites:

- **Límite Inferior:** $Q_1 - 1,5 \times IQR$
- **Límite Superior:** $Q_3 + 1,5 \times IQR$

Cualquier valor fuera de este rango se considera un *outlier*. En el contexto de este dataset médico, estas observaciones representan pacientes con recuentos de lesiones (microaneurismas o exudados) inusualmente altos o bajos en comparación con la población general de la muestra.

4.4.2. Resultados de la Detección

Se analizaron los atributos de microaneurismas (**ma1** a **ma6**), los cuales representan el conteo de lesiones detectadas con niveles de confianza crecientes ($\alpha = 0,5$ a $1,0$). Los resultados obtenidos se detallan en la siguiente tabla:

Tabla 4: Outliers identificados en variables de microaneurismas.

Variable	Outliers Identificados	Índices
ma1	7	[129, 280, 332, 339, 560, 575, 1077]
ma2	6	[129, 280, 332, 339, 575, 1077]
ma3	4	[332, 339, 575, 1077]
ma4	1	[339]
ma5	1	[271]
ma6	3	[14, 271, 648]

Validación Clínica y Correlación con la Patología Al verificar la variable objetivo (**Class**) para cada outlier detectado, se determinó que **la gran mayoría pertenece a la Clase 1** (pacientes con signos de retinopatía diabética), lo que permite concluir que estos valores extremos representan **manifestaciones clínicas de alta severidad** y no errores de medición. La única excepción es el índice 14, identificado como outlier en **ma6** ($\alpha = 1,0$), que corresponde a un paciente de la **Clase 0** (sano). Este caso aislado puede explicarse porque, bajo el criterio de mayor confianza, el detector captura conteos elevados que no necesariamente implican patología confirmada, lo que refleja la naturaleza probabilística del sistema de clasificación automatizado. Esto respalda lo expuesto por Casanova et al. (2014), quienes establecen que el conteo de microaneurismas es la variable de mayor importancia para discriminar la presencia de la enfermedad. La disminución del número de outliers a medida que aumenta el nivel de confianza (α) sugiere que solo las lesiones más evidentes y voluminosas persisten bajo criterios de detección estrictos.

4.4.3. Visualización mediante Boxplots por Clase

Se generaron diagramas de cajas (Boxplots) para comparar la dispersión de las lesiones entre los grupos de control (**Clase 0**) y pacientes con signos de RD (**Clase 1**).




Figura 1: Diagrama de cajas entre las Clases 0 y 1.

Interpretación de la Figura

1. **Diferencia de tendencia:** La Clase 1 (naranja) muestra una mediana y un rango intercuartílico notablemente superiores a la Clase 0 (verde).
2. **Presencia de extremos:** Mientras que la Clase 0 se mantiene compacta, la Clase 1 presenta una serie de puntos aislados que superan los 140 microaneurismas, coincidiendo con los índices identificados previamente.
3. **Justificación de la no normalidad:** La existencia de estos valores atípicos extremos hacia el límite superior explica la asimetría positiva y el rechazo de la hipótesis de normalidad en las pruebas de Shapiro-Wilk, validando la necesidad de utilizar estadística no paramétrica en este estudio.

4.5. Análisis de Correlación y Visualización (Heatmap)

Para identificar las relaciones lineales entre los 19 atributos y la variable de diagnóstico (**Class**), se calculó la matriz de correlación de Pearson utilizando las librerías **pandas** (Team, 2024) y **seaborn** (Waskom, 2021) en Python. Este análisis es fundamental para detectar redundancias (colinealidad) y determinar cuáles rasgos anatómicos o lesiones tienen un mayor vínculo con la presencia de la patología.




Figura 2: Mapa de calor basado en la matriz de correlaciones.

4.5.1. Interpretación del Mapa de Calor

El análisis visual del mapa de calor permite extraer las siguientes conclusiones técnicas:

1. **Alta Colinealidad en Microaneurismas (ma1 a ma6):** Se observa una correlación positiva extremadamente alta, cercana a 1,00 en la mayoría de los casos. Por ejemplo, la correlación entre `ma1` y `ma2` es de 1,00, y entre `ma1` y `ma3` es de 0,99.
 - *Fundamentación:* Esto confirma que estos atributos representan el mismo fenómeno clínico (conteo de microaneurismas) detectado con niveles de confianza (α) crecientes. La alta redundancia sugiere que, para futuros modelos de clasificación, se podría realizar una reducción de dimensionalidad sin perder información crítica.
2. **Correlación con la Variable Objetivo (Class):** Los resultados muestran que los microaneurismas son los descriptores con la relación más fuerte hacia el diagnóstico final.
 - Las variables `ma1` (0,29) y `ma2` (0,27) presentan los coeficientes de correlación más altos con `Class` dentro de su grupo.
 - *Significancia:* Este hallazgo es coherente con el estudio de Casanova et al. (2014), el cual establece mediante criterios de importancia de variables que el conteo de microaneurismas desempeña el papel más relevante en la discriminación de la enfermedad.
3. **Relación entre Exudados:** Al igual que con los microaneurismas, se observan clústeres de alta correlación entre los niveles de detección de exudados, particularmente entre `exudate2`, `exudate3` y `exudate4` (valores entre 0,92 y 1,00). Su correlación con la variable `Class` es positiva pero moderada (máximo de 0,18 en `exudate7`), indicando que, aunque son indicadores de RD, su peso diagnóstico individual en este dataset es menor al de los microaneurismas.
4. **Independencia de Rasgos Anatómicos:** Atributos como `macula_opticdisc_distance` (0,01) y `optic_disc_diameter` (-0,03) muestran una correlación prácticamente nula con la presencia de la enfermedad en este conjunto de datos. Esto sugiere que la patología se manifiesta principalmente

a través de lesiones detectables (MA y exudados) antes de generar cambios anatómicos macroscópicos detectables por estos descriptores específicos.

4.5.2. Conclusión del Análisis de Correlación

El mapa de calor valida la hipótesis de que las lesiones retinales, específicamente los **microaneurismas detectados con niveles de confianza iniciales**, son los mejores predictores lineales de la patología en este dataset. Además, la fuerte colinealidad interna entre las variables de lesiones justifica el uso de pruebas de significancia que traten estos grupos como una dimensión común de daño neurovascular (Casanova et al., 2014).

4.6. Comparación de Grupos (Prueba Mann-Whitney U)

Tras confirmar en la sección anterior que las variables de microaneurismas (`ma1` a `ma6`) no siguen una distribución normal según el test de Shapiro-Wilk, se procedió a realizar un análisis inferencial de comparación de grupos mediante la prueba de Mann-Whitney U. Esta prueba no paramétrica permite determinar si existen diferencias estadísticamente significativas en las medianas de los conteos de lesiones entre pacientes sanos (Clase 0) y pacientes con diagnóstico de retinopatía (Clase 1).

4.6.1. Planteamiento de Hipótesis

- Hipótesis Nula (H_0): No existe una diferencia significativa en la distribución del conteo de microaneurismas entre el grupo sano y el grupo con retinopatía diabética.
- Hipótesis Alternativa (H_1): Existe una diferencia significativa en la distribución del conteo de microaneurismas entre ambos grupos.

4.6.2. Resultados de la Prueba

Los estadísticos obtenidos mediante la librería `scipy.stats` se detallan en la siguiente tabla:

Tabla 5: Resultados de la prueba Mann-Whitney U para microaneurismas.

Variable	U_statistic	p_value	Significativo
ma1	111208	$1,25 \times 10^{-21}$	Sí
ma2	116076	$3,67 \times 10^{-18}$	Sí
ma3	121532	$1,17 \times 10^{-14}$	Sí
ma4	127750	$3,73 \times 10^{-11}$	Sí
ma5	133506	$2,25 \times 10^{-08}$	Sí
ma6	139938	$8,62 \times 10^{-06}$	Sí

4.6.3. Interpretación de los Hallazgos

El análisis de los resultados permite extraer las siguientes conclusiones fundamentales para el estudio:

1. **Rechazo de la hipótesis nula:** En todos los niveles de confianza (α de 0,5 a 1,0), los p-valores son extremadamente bajos (siendo el mayor $8,61 \times 10^{-6}$ para **ma6**), situándose muy por debajo del umbral de significancia de 0,05. Esto permite rechazar H_0 y confirmar que las diferencias observadas entre pacientes sanos y enfermos no son producto del azar.
2. **Sensibilidad del diagnóstico:** Se observa que la significancia estadística es más aguda en los niveles de confianza iniciales (**ma1** y **ma2**). El p-valor más bajo se registró en **ma1** ($1,25 \times 10^{-21}$), lo que sugiere que el conteo de lesiones detectadas incluso con una sensibilidad moderada ($\alpha = 0,5$) es un potente discriminador de la enfermedad.
3. **Consistencia con la literatura:** Estos resultados validan empíricamente lo expuesto por Casanova et al. (2014), quienes identifican al conteo de microaneurismas como el rasgo de mayor importancia diagnóstica entre todas las variables extraídas de imágenes de fondo de ojo.
4. **Confirmación de biomarcadores:** La prueba estadística ratifica lo observado visualmente en los diagramas de caja y en el análisis de valores atípicos, consoli-

dando al recuento de MA como un biomarcador clínico robusto para la clasificación automatizada en este dataset.

4.7. Homogeneidad de Varianzas (Test de Levene)

Tras confirmar la no normalidad de los datos, se aplicó el **Test de Levene** para evaluar si las varianzas de los microaneurismas son homogéneas entre pacientes sanos (Clase 0) y con retinopatía (Clase 1). A diferencia de la Prueba F clásica, el test de Levene no asume normalidad en los datos, siendo el método adecuado para este caso.

4.7.1. Planteamiento de Hipótesis

- Hipótesis Nula (H_0): Las varianzas de ambos grupos son iguales (homocedasticidad).
- Hipótesis Alternativa (H_1): Las varianzas de ambos grupos son significativamente distintas (heterocedasticidad).

4.7.2. Resultados

Tabla 6: Resultados del Test de Levene para microaneurismas.

Variable	Estadístico	p_value	Homocedasticidad
ma1	35.9975	$2,64 \times 10^{-9}$	No (varianzas distintas)
ma2	23.6750	$1,30 \times 10^{-6}$	No (varianzas distintas)
ma3	16.6036	$4,92 \times 10^{-5}$	No (varianzas distintas)
ma4	10.6155	$1,15 \times 10^{-3}$	No (varianzas distintas)
ma5	5.9695	$1,47 \times 10^{-2}$	No (varianzas distintas)
ma6	4.5424	$3,33 \times 10^{-2}$	No (varianzas distintas)

4.7.3. Interpretación

En todas las variables de microaneurismas se rechaza la hipótesis nula ($p < 0,05$), lo que confirma que las varianzas entre pacientes sanos y con retinopatía son significativamente distintas. La heterocedasticidad es más pronunciada en los niveles de confianza bajos (**ma1**, estadístico = 35,99) y se atenúa a medida que aumenta el umbral de detección (**ma6**, estadístico = 4,54), aunque sin llegar a ser homogéneas en ningún caso. Este hallazgo es consistente con los boxplots previos, donde la Clase 1 mostró mayor dispersión en el conteo de lesiones, y refuerza la evidencia de que la retinopatía no solo eleva el promedio de microaneurismas sino también su variabilidad dentro del grupo de pacientes afectados.

4.8. Modelamiento mediante Regresión Logística

Para modelar la probabilidad de presencia de retinopatía diabética en función de los descriptores clínicos y anatómicos, se implementó un modelo de Regresión Logística. A diferencia de la regresión lineal, este método es el estándar estadístico adecuado para variables dependientes binarias, como la variable **Class** de este estudio (0 = Sano, 1 = RD), permitiendo identificar qué factores incrementan significativamente el riesgo de padecer la patología.

4.8.1. Justificación de la Selección de Atributos

Para este modelo se seleccionó un subconjunto representativo de cuatro variables: **ma1**, **exudate1**, **macula_opticdisc_distance** y **opticdisc_diameter**. Se excluyeron los 15 atributos restantes por los siguientes criterios técnicos:

- **Prevención de la multicolinealidad:** El análisis de correlación previo demostró una colinealidad casi perfecta ($r \approx 1,0$) entre las variables de microaneurismas (**ma1–ma6**) y entre los niveles de exudados. Incluir variables altamente redundantes inflaría los errores estándar, invalidando la significancia de los coeficientes. Se seleccionaron **ma1** y **exudate1** como representantes de la carga lesional.

- **Representación dimensional:** El subconjunto elegido permite evaluar las tres dimensiones críticas del dataset: lesiones vasculares (MAs), depósitos lipídicos (exudados) y rasgos anatómicos estructurales (distancia y diámetro del disco).
- **Parsimonia y relevancia clínica:** Siguiendo los hallazgos de Casanova et al. (2014), se priorizaron los microaneurismas por ser la variable de mayor importancia para la discriminación de la enfermedad, buscando un modelo eficiente que evite el “ruido” de variables con nulo aporte lineal.

4.8.2. Evaluación Global y Bondad de Ajuste

El modelo fue evaluado sobre un conjunto de prueba del 20 % (231 instancias), obteniendo un área bajo la curva **AUC de 0,65**, lo que indica una capacidad predictiva moderada. Esto sugiere que, si bien el modelo identifica patrones relevantes, la relación entre los predictores y el diagnóstico presenta una complejidad que un modelo lineal simple no logra capturar en su totalidad.




Figura 3: Matriz de confusión y Curva ROC-AUC.

4.8.3. Interpretación de los Coeficientes y Significancia

Al analizar los resultados individuales de la regresión, se extraen las siguientes conclusiones:

- **Significancia crítica de microaneurismas (ma1):** Con un p-valor de 0,000 y un coeficiente positivo (0,0307), se confirma que el aumento en el conteo de lesiones vasculares eleva significativamente la probabilidad de diagnóstico positivo. Este hallazgo valida empíricamente la tesis de Casanova et al. (2014), situando a los MAs como el biomarcador más robusto para la clasificación automatizada.
- **Impacto de exudados (exudate1):** Esta variable también resultó ser un predictor significativo (p-valor = 0,000), reafirmando que la presencia de depósitos de lípidos es un indicador primario de la patología en este dataset.
- **Irrelevancia de rasgos anatómicos:** Tanto la distancia mácula-disco ($p = 0,632$) como el diámetro del disco ($p = 0,330$) no mostraron significancia estadística. Esto sugiere que, para este conjunto de datos, las lesiones retinales son predictores mucho más potentes de la enfermedad que las variaciones en la estructura geométrica básica del ojo.

4.8.4. Evaluación de Desempeño (Matriz de Confusión y ROC)

La capacidad de clasificación del modelo se evaluó mediante los resultados en el conjunto de prueba:

1. Matriz de Confusión:

- **Verdaderos Positivos (TP):** 79 pacientes con RD correctamente identificados.
- **Verdaderos Negativos (TN):** 58 pacientes sanos correctamente identificados.
- **Falsos Negativos (FN):** 49 casos de RD no detectados, lo que arroja una sensibilidad del 61,7 %.
- **Falsos Positivos (FP):** 45 casos sanos clasificados erróneamente, resultando en una especificidad del 56,3 %.

2. **Curva ROC-AUC:** El valor obtenido de 0,65 sitúa el desempeño del modelo por encima del azar (0,5), pero significativamente por debajo de los estándares de alta precisión clínica, como el 0,989 alcanzado por sistemas de ensamble en la literatura (Casanova et al., 2014). Esto confirma que las cuatro variables seleccionadas son necesarias pero insuficientes para un diagnóstico automatizado de alta fidelidad, requiriendo modelos de inteligencia computacional más robustos.

4.8.5. Validación de Residuos

Como complemento al análisis de desempeño, se examinó la distribución de los residuos del modelo, calculados como la diferencia entre la clase real y la probabilidad predicha. Un modelo bien ajustado debería presentar residuos centrados en cero y sin sesgos sistemáticos.




Figura 4: Histograma de residuos del modelo de regresión logística con curva de densidad superpuesta.

La distribución muestra dos agrupaciones características de la regresión logística binaria: una concentración negativa (pacientes sanos clasificados con alta probabilidad de RD) y una positiva (pacientes con RD clasificados con baja probabilidad).

La curva de densidad confirma que los residuos no siguen una distribución normal, lo cual es esperado en modelos de clasificación binaria y no constituye una violación de los supuestos del método.

5. Conclusiones

El análisis estadístico e inferencial realizado sobre el dataset **Diabetic Retinopathy Debrecen** permitió validar las hipótesis fundamentales sobre la naturaleza de la patología y la relevancia de sus biomarcadores.

5.1. Síntesis de Hallazgos Principales

Se confirmó matemáticamente la **no normalidad** de las variables de lesiones y una marcada asimetría positiva, coherente con la distribución clínica de la enfermedad. La validación de outliers mediante el método de Tukey fue determinante: el 100 % de los valores extremos **pertenecen a la Clase 1**, demostrando que los recuentos elevados de microaneurismas son indicadores inequívocos de estadios severos de la RD.

5.2. Discusión de Resultados y Desempeño del Modelo

Las pruebas de **Mann-Whitney U** y la **Regresión Logística** coinciden en señalar a los microaneurismas (**ma1**) como la variable de mayor peso diagnóstico ($p < 0,05$), respaldando lo expuesto por Casanova et al. (2014). No obstante, la evaluación de desempeño reveló limitaciones críticas: una sensibilidad del 61,7 % y un AUC de 0,65. Estos valores indican que, aunque la carga lesional es un indicador estadísticamente significativo, un modelo logístico lineal no es suficiente para discriminar con precisión entre clases, especialmente en etapas tempranas donde el solapamiento de datos es alto (según se observó en los diagramas de caja).

5.3. Limitaciones y Proyecciones Futuras

La principal limitación radica en la incapacidad del modelo lineal para capturar la variabilidad total del diagnóstico ($\text{Pseudo } R^2 = 0,087$). Como proyección futura, se hace imperativo el uso de algoritmos de inteligencia computacional no lineales, como *Random Forests* o redes neuronales, que puedan explotar la alta colinealidad detectada en el mapa de calor y mejorar la tasa de detección de casos positivos, acercándose a los

niveles de sensibilidad clínica exigidos para sistemas de cribado automático.

Anexos

Referencias

- Abràmoff, M. D., Garvin, M. K., & Sonka, M. (2010). Retinal imaging and image analysis. *IEEE Reviews in Biomedical Engineering*, 3, 169-208. <https://doi.org/10.1109/RBME.2010.2084567>
- Antal, B., & Hajdu, A. (2014a). Diabetic Retinopathy Debrecen. <https://doi.org/10.24432/C5XP4P>
- Antal, B., & Hajdu, A. (2014b). An ensemble-based system for automatic screening of diabetic retinopathy. *Knowledge-Based Systems*. <https://doi.org/10.1016/j.knsys.2014.01.007>
- Casanova, R., Saldana, S., Chew, E. Y., Danis, R. P., Greven, C. M., & Ambrosius, W. T. (2014). Application of Random Forests Methods to Diabetic Retinopathy Classification Analyses. *PLoS ONE*, 9(6), e98587. <https://doi.org/10.1371/journal.pone.0098587>
- Kelly, M., Longjohn, C., & Nottingham, K. (2023). ucimlrepo: Python wrapper for the UCI Machine Learning Repository. <https://github.com/uci-ml-repo/ucimlrepo>
- Team, T. P. D. (2024, febrero). *pandas-dev/pandas: Pandas* (Ver. latest). Zenodo. <https://doi.org/10.5281/zenodo.3509134>
- Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, 17, 261-272. <https://doi.org/10.1038/s41592-019-0686-2>
- Waskom, M. L. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>
- Wilkinson, C. P., Ferris III, F. L., Klein, R. E., Lee, P. P., Agardh, C. D., Davis, M., Dills, D., Kampik, A., Pararajasegaram, R., & Verdaguer, J. T. (2003). Proposed international clinical diabetic retinopathy and diabetic macular edema disease severity scales. *Ophthalmology*, 110(9), 1677-1682. [https://doi.org/10.1016/S0161-6420\(03\)00475-5](https://doi.org/10.1016/S0161-6420(03)00475-5)