

UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
Departamento de Ingeniería Informática



Laboratorio 1
Diabetic Retinopathy Debrecen

Integrantes: Gonzalo Ahumada
Daniel Muñoz
Asignatura: Inteligencia Computacional
Profesor: Max Chacón
Ayudante: Sebastián Chávez

29 de abril de 2026

Tabla de contenidos

1. Introducción	1
1.1. Contextualización y Antecedentes	1
1.2. Objetivos del Laboratorio	1
1.3. Formulación de Hipótesis	2
2. Descripción del Problema	2
2.1. Descripción de la Base de Datos (Diabetic Retinopathy Debrecen) . . .	2
2.2. Descripción de Clases y Variables	2
2.2.1. Variables de Calidad y Pre-procesamiento	3
2.2.2. Detección de Lesiones y Niveles de Confianza	3
2.2.3. Descriptores Anatómicos	3
2.2.4. Variable de Clase (Objetivo)	4
3. Marco Teórico	5
3.1. Retinopatía Diabética e Importancia Médica de las Lesiones	5
3.2. Fundamentos de Estadística Descriptiva y Forma de Distribución . . .	5
3.3. Fundamentos de Estadística Inferencial y Pruebas de Hipótesis	6
4. Análisis Estadístico e Inferencial	7
4.1. Resumen Estadístico Descriptivo	7
4.2. Análisis de la Forma de la Distribución (Asimetría y Curtosis)	8
4.3. Validación de Normalidad (Prueba de Shapiro-Wilk)	8
4.4. Detección de Valores Atípicos (Outliers)	9
4.4.1. Metodología de Tukey	9
4.4.2. Resultados de la Detección	10
4.4.3. Visualización mediante Boxplots por Clase	11
4.5. Análisis de Correlación y Visualización (Heatmap)	12
4.5.1. Interpretación del Mapa de Calor	13
4.5.2. Conclusión del Análisis de Correlación	14
4.6. Comparación de Grupos (Prueba Mann-Whitney U)	14

4.6.1.	Planteamiento de Hipótesis	14
4.6.2.	Resultados de la Prueba	15
4.6.3.	Interpretación de los Hallazgos	15
4.7.	Modelamiento mediante Regresión Logística	16
4.7.1.	Justificación de la Selección de Atributos	16
4.7.2.	Evaluación Global y Bondad de Ajuste	17
4.7.3.	Interpretación de los Coeficientes y Significancia	17
4.7.4.	Evaluación de Desempeño (Matriz de Confusión y ROC)	18
5.	Conclusiones	20
5.1.	Síntesis de Hallazgos Principales	20
5.2.	Discusión de Resultados y Desempeño del Modelo	20
5.3.	Limitaciones y Proyecciones Futuras	20
	Bibliografía	23

1. Introducción

1.1. Contextualización y Antecedentes

La retinopatía diabética (RD) representa una de las principales causas de pérdida de visión a nivel mundial y es considerada una “enfermedad silenciosa”, ya que a menudo progresa sin síntomas detectables hasta que las opciones de tratamiento son limitadas (Casanova et al., 2014). La detección temprana es fundamental para permitir intervenciones terapéuticas eficaces, pero los métodos tradicionales de examen clínico enfrentan barreras como la variabilidad entre observadores y la falta de especialistas en zonas rurales (Casanova et al., 2014). Esto ha impulsado el desarrollo de sistemas automatizados de tamizaje que utilizan técnicas de procesamiento de imágenes y aprendizaje de máquinas para identificar lesiones retinales de manera objetiva (Antal & Hajdu, 2014b).

Para el desarrollo de este laboratorio, se analiza el conjunto de datos *Diabetic Retinopathy Debrecen*, el cual consiste en 1.151 instancias y 19 atributos extraídos del conjunto de imágenes Messidor (Antal & Hajdu, 2014a). Estos atributos capturan características críticas para el diagnóstico, incluyendo el conteo de microaneurismas en diversos niveles de confianza, la cantidad normalizada de exudados y descriptores anatómicos como la distancia entre la mácula y el disco óptico (Antal & Hajdu, 2014a). La literatura científica sugiere que el conteo de microaneurismas es el factor de mayor peso para discriminar la presencia de la enfermedad en modelos computacionales (Casanova et al., 2014).

1.2. Objetivos del Laboratorio

General: Estudiar e interpretar los datos del dataset seleccionado para comprender el significado de sus atributos y su relación con la detección de la RD (Antal & Hajdu, 2014a).

Específicos:

1. Realizar un análisis estadístico descriptivo para resumir las características funda-

mentales del conjunto de datos.

2. Aplicar técnicas de estadística inferencial, incluyendo pruebas de normalidad y de hipótesis, para determinar la significación de los resultados obtenidos.
3. Identificar qué variables presentan diferencias significativas entre pacientes sanos y aquellos con signos de la patología.

1.3. Formulación de Hipótesis

Se postula que las variables relacionadas con el conteo de lesiones, específicamente los microaneurismas (**ma1** a **ma6**), presentarán distribuciones significativamente distintas entre las clases de control y de enfermedad. Se espera que estas variables, junto con los exudados, actúen como los principales indicadores para la clasificación, dada su relevancia clínica documentada en el diagnóstico de la severidad de la retinopatía.

2. Descripción del Problema

2.1. Descripción de la Base de Datos (Diabetic Retinopathy Debrecen)

Este conjunto de datos contiene atributos extraídos del set de imágenes Mesidor (Antal & Hajdu, 2014a). Consta de 1.151 instancias y 19 atributos que representan lesiones detectadas, rasgos anatómicos (distancia mácula-disco óptico) y descriptores de nivel de imagen (Antal & Hajdu, 2014a). El dataset es de naturaleza multivariada y se utiliza principalmente para tareas de clasificación binaria (clase 1 para signos de RD y clase 0 para ausencia) (Antal & Hajdu, 2014a).

2.2. Descripción de Clases y Variables

A continuación, se detalla la naturaleza y relevancia de cada una de las 19 variables del conjunto de datos:

2.2.1. Variables de Calidad y Pre-procesamiento

- **quality**: Atributo binario que indica el resultado de la evaluación de calidad de la imagen de fondo de ojo (0 = calidad insuficiente, 1 = calidad suficiente para el diagnóstico).
- **pre_screening**: Variable binaria de pre-cribado donde el valor 1 señala la presencia de una anomalía retiniana grave y 0 su ausencia.
- **am_fm_classification**: Resultado binario derivado de un sistema de clasificación automatizado basado en métodos de AM/FM.

2.2.2. Detección de Lesiones y Niveles de Confianza

- **ma1 a ma6** (Microaneurismas): Representan el conteo de microaneurismas (MA) detectados mediante algoritmos de procesamiento de imágenes. La literatura identifica a los microaneurismas como el factor de mayor importancia para discriminar la presencia de la enfermedad.
 - **Nota técnica sobre los niveles de confianza**: La distinción entre estas seis variables radica en el nivel de confianza (α) del detector, que escala desde $\alpha = 0,5$ (**ma1**) hasta $\alpha = 1,0$ (**ma6**). Un nivel de confianza más elevado implica criterios de detección más estrictos, lo que reduce la probabilidad de falsos positivos pero incrementa el riesgo de omitir lesiones reales y sutiles.
- **exudate1 a exudate8**: Corresponden a la detección de exudados duros (depósitos de lípidos). A diferencia de los MA, estos valores están normalizados dividiendo el número de lesiones por el diámetro de la Región de Interés (ROI) para compensar las variaciones en el tamaño de las imágenes.

2.2.3. Descriptores Anatómicos

- **euclidean_distance**: Distancia euclidiana normalizada entre el centro de la mácula y el centro del disco óptico. Proporciona información crítica sobre la condición anatómica del paciente.

- `optic_disc_diameter`: Medida del diámetro del disco óptico extraída de la imagen.

2.2.4. Variable de Clase (Objetivo)

Class: Etiqueta binaria de salida que define el estado diagnóstico del paciente.

- 1: Indica que la imagen presenta signos de retinopatía diabética (corresponde a una etiqueta acumulativa de las clases 1, 2 y 3 de la base Messidor).
- 0: Indica la ausencia total de signos de la patología.

3. Marco Teórico

3.1. Retinopatía Diabética e Importancia Médica de las Lesiones

La retinopatía diabética (RD) es una de las principales causas de ceguera en el mundo y se caracteriza por ser una “enfermedad silenciosa” que a menudo progresa sin síntomas hasta etapas críticas (Casanova et al., 2014). La detección temprana es vital para la eficacia del tratamiento. Clínicamente, el diagnóstico se basa en la identificación de lesiones en la retina:

- **Microaneurismas (MA):** Son las primeras lesiones detectables y se consideran el factor de mayor importancia para discriminar la presencia de la enfermedad en análisis computacionales (Casanova et al., 2014).
- **Exudados:** Depósitos de lípidos que filtran de vasos dañados (Casanova et al., 2014). En el análisis de datos, estos se normalizan según el diámetro de la Región de Interés (ROI) para compensar variaciones en el tamaño de las imágenes (Antal & Hajdu, 2014a).

3.2. Fundamentos de Estadística Descriptiva y Forma de Distribución

El análisis descriptivo permite resumir las características fundamentales de los datos para proporcionar una visión clara del conjunto (Chacón Pacheco & Chavez Orellana, 2026).

- **Medidas de tendencia central y dispersión:** Incluyen la media aritmética, la desviación estándar para medir la dispersión respecto a la media, y la mediana como medida robusta de centro (Chavez Orellana, 2026).
- **Forma de la distribución:** La asimetría (*skewness*) indica la falta de simetría, mientras que la curtosis mide si la distribución es más puntiaguda o aplanada que una normal (Chavez Orellana, 2026).

- **Detección de valores atípicos:** Se fundamenta en el método de Tukey, que utiliza el Rango Intercuartílico (IQR) para establecer límites inferiores y superiores, identificando observaciones que podrían sesgar el análisis (Chavez Orellana, 2026).

3.3. Fundamentos de Estadística Inferencial y Pruebas de Hipótesis

La estadística inferencial busca obtener conclusiones sobre la población a partir de la muestra mediante pruebas de significación (Chavez Orellana, 2026).

- **Prueba de normalidad (Shapiro-Wilk):** Evalúa si los datos siguen una distribución normal. Un p-valor menor a 0,05 permite rechazar la hipótesis nula de normalidad (Chavez Orellana, 2026).
- **Comparación de grupos (prueba t de Student):** Se utiliza para determinar si existe una diferencia significativa entre las medias de dos grupos independientes (ej. sanos vs. enfermos) (Chavez Orellana, 2026).
- **Homocedasticidad:** Pruebas como el test de Bartlett evalúan si las varianzas de los grupos son iguales, un requisito previo para la validez de muchas pruebas paramétricas (Chavez Orellana, 2026).

Para el desarrollo técnico se emplean bibliotecas estándar de la industria que garantizan la reproducibilidad (Chavez Orellana, 2026): *Pandas* (Team, 2024) para estructuras de datos y estadísticas descriptivas, *SciPy* (`scipy.stats`) (Virtanen et al., 2020) para pruebas estadísticas inferenciales, y *ucimlrepo* (Kelly et al., 2023) para la importación directa de datasets desde el repositorio UCI Machine Learning.

4. Análisis Estadístico e Inferencial

En esta sección se presentan los resultados del análisis de los 19 atributos del dataset **Diabetic Retinopathy Debrecen**, procesados mediante el lenguaje Python y las librerías `pandas` y `scipy.stats`.

4.1. Resumen Estadístico Descriptivo

Tabla 1: Tabla de estadísticos descriptivos, los nombres y siglas están en inglés.

Variable	count	mean	std	min	max
quality	1151	0.996525	0.0588742	0	1
pre_screening	1151	0.918332	0.273977	0	1
ma1	1151	38.4283	25.6209	1	151
ma2	1151	36.9096	24.1056	1	132
ma3	1151	35.1407	22.8054	1	120
ma4	1151	32.2971	21.1148	1	105
ma5	1151	28.7472	19.5092	1	97
ma6	1151	21.1512	15.1016	1	89
exudate1	1151	64.0967	58.4853	0.349274	403.939
exudate2	1151	23.088	21.6027	0	167.131
exudate3	1151	8.70461	11.5676	0	106.07
exudate4	1151	8.70461	11.5676	0	106.07
exudate5	1151	0.560738	2.48411	0	51.4232
exudate6	1151	0.21229	1.05713	0	20.0986
exudate7	1151	0.0856741	0.398717	0	5.9378
exudate8	1151	0.0372251	0.178959	0	3.08675
macula_opticdisc_distance	1151	0.523212	0.0280554	0.367762	0.592217
opticdisc_diameter	1151	0.108431	0.0179448	0.057906	0.219199
am_fm_classification	1151	0.336229	0.472624	0	1

4.2. Análisis de la Forma de la Distribución (Asimetría y Curtosis)

Para las variables críticas de microaneurismas (**ma1** a **ma6**), identificadas en la literatura (Casanova et al., 2014) como los predictores más importantes para la detección de la RD, se evaluó su asimetría y curtosis:

Tabla 2: Tabla de asimetría y curtosis para los microaneurismas.

Variable	Asimetría (skew)	Curtosis
ma1	0.743916	0.333756
ma2	0.62517	-0.0999926
ma3	0.532673	-0.468193
ma4	0.498474	-0.673164
ma5	0.533248	-0.692618
ma6	0.722384	-0.102349

Todas las variables de MA presentan una asimetría positiva, lo que indica que la distribución tiene una cola alargada hacia la derecha. Esto es coherente con un dataset médico donde muchos pacientes tienen pocos signos de lesión y una minoría presenta conteos elevados.

4.3. Validación de Normalidad (Prueba de Shapiro-Wilk)

Para formalizar la observación de la forma, se aplicó el test de **Shapiro-Wilk** bajo la hipótesis nula (H_0) de que los datos siguen una distribución normal:

Dado que en todos los casos el **p-valor** $< 0,05$, se rechaza la hipótesis nula. Esto confirma matemáticamente que los conteos de microaneurismas no se distribuyen de forma normal, lo cual condiciona el uso de pruebas no paramétricas para las comparaciones de grupos posteriores.

Tabla 3: Tabla de validación de normalidad para los microaneurismas.

Variable	W	p-value	Distribución
ma1	0.945107	$2,94 \times 10^{-20}$	No Normal
ma2	0.950456	$3,02 \times 10^{-19}$	No Normal
ma3	0.950985	$3,84 \times 10^{-19}$	No Normal
ma4	0.947417	$7,86 \times 10^{-20}$	No Normal
ma5	0.938654	$2,18 \times 10^{-21}$	No Normal
ma6	0.929734	$8,23 \times 10^{-23}$	No Normal

4.4. Detección de Valores Atípicos (Outliers)

Para garantizar la robustez del análisis y comprender la variabilidad extrema en los datos, se realizó la detección de valores atípicos mediante el **método de Tukey** (Chacón Pacheco & Chavez Orellana, 2026). Esta técnica es preferida en estudios clínicos debido a que utiliza medidas de posición no sensibles a los extremos, permitiendo identificar observaciones que se desvían significativamente del comportamiento central del grupo.

4.4.1. Metodología de Tukey

La identificación se basó en el cálculo del Rango Intercuartílico ($IQR = Q_3 - Q_1$), estableciendo los siguientes límites:

- **Límite Inferior:** $Q_1 - 1,5 \times IQR$
- **Límite Superior:** $Q_3 + 1,5 \times IQR$

Cualquier valor fuera de este rango se considera un *outlier*. En el contexto de este dataset médico, estas observaciones representan pacientes con recuentos de lesiones (microaneurismas o exudados) inusualmente altos o bajos en comparación con la población general de la muestra.

4.4.2. Resultados de la Detección

Se analizaron los atributos de microaneurismas (ma1 a ma6), los cuales representan el conteo de lesiones detectadas con niveles de confianza crecientes ($\alpha = 0,5$ a 1,0). Los resultados obtenidos se detallan en la siguiente tabla:

Tabla 4: Outliers identificados en variables de microaneurismas.

Variable	Outliers Identificados	Índices
ma1	7	[129, 280, 332, 339, 560, 575, 1077]
ma2	6	[129, 280, 332, 339, 575, 1077]
ma3	4	[332, 339, 575, 1077]
ma4	1	[339]
ma5	1	[271]
ma6	3	[14, 271, 648]

Validación Clínica y Correlación con la Patología Un hallazgo crítico de este análisis fue la validación de la etiqueta de diagnóstico para los valores extremos. Al verificar la variable objetivo (Class), se determinó que **el 100% de los índices evaluados (129, 280, 332, 339, 575 y 1077) pertenecen a la Clase 1**, correspondiente a pacientes con signos de retinopatía diabética. Esta coincidencia absoluta permite concluir que los outliers detectados no son errores de medición o ruido en los datos, sino **manifestaciones clínicas de alta severidad**. Esto respalda lo expuesto por Casanova et al. (2014), quienes establecen que el conteo de microaneurismas es la variable de mayor importancia para discriminar la presencia de la enfermedad. La disminución del número de outliers a medida que aumenta el nivel de confianza (α) sugiere que solo las lesiones más evidentes y voluminosas persisten bajo criterios de detección estrictos.

4.4.3. Visualización mediante Boxplots por Clase

Se generaron diagramas de cajas (Boxplots) para comparar la dispersión de las lesiones entre los grupos de control (**Clase 0**) y pacientes con signos de RD (**Clase 1**).




Figura 1: Diagrama de cajas entre las Clases 0 y 1.

Interpretación de la Figura

1. **Diferencia de tendencia:** La Clase 1 (naranja) muestra una mediana y un rango intercuartílico notablemente superiores a la Clase 0 (verde).
2. **Presencia de extremos:** Mientras que la Clase 0 se mantiene compacta, la Clase 1 presenta una serie de puntos aislados que superan los 140 microaneurismas, coincidiendo con los índices identificados previamente.
3. **Justificación de la no normalidad:** La existencia de estos valores atípicos extremos hacia el límite superior explica la asimetría positiva y el rechazo de la hipótesis de normalidad en las pruebas de Shapiro-Wilk, validando la necesidad de utilizar estadística no paramétrica en este estudio.

4.5. Análisis de Correlación y Visualización (Heatmap)

Para identificar las relaciones lineales entre los 19 atributos y la variable de diagnóstico (**Class**), se calculó la matriz de correlación de Pearson utilizando las librerías **pandas** (Team, 2024) y **seaborn** (Waskom, 2021) en Python. Este análisis es fundamental para detectar redundancias (colinealidad) y determinar cuáles rasgos anatómicos o lesiones tienen un mayor vínculo con la presencia de la patología.




Figura 2: Mapa de calor basado en la matriz de correlaciones.

4.5.1. Interpretación del Mapa de Calor

El análisis visual del mapa de calor permite extraer las siguientes conclusiones técnicas:

1. **Alta Colinealidad en Microaneurismas (ma1 a ma6):** Se observa una correlación positiva extremadamente alta, cercana a 1,00 en la mayoría de los casos. Por ejemplo, la correlación entre **ma1** y **ma2** es de 1,00, y entre **ma1** y **ma3** es de 0,99.
 - *Fundamentación:* Esto confirma que estos atributos representan el mismo fenómeno clínico (conteo de microaneurismas) detectado con niveles de confianza (α) crecientes. La alta redundancia sugiere que, para futuros modelos de clasificación, se podría realizar una reducción de dimensionalidad sin perder información crítica.
2. **Correlación con la Variable Objetivo (Class):** Los resultados muestran que los microaneurismas son los descriptores con la relación más fuerte hacia el diagnóstico final.
 - Las variables **ma1** (0,29) y **ma2** (0,27) presentan los coeficientes de correlación más altos con **Class** dentro de su grupo.
 - *Significancia:* Este hallazgo es coherente con el estudio de Casanova et al. (2014), el cual establece mediante criterios de importancia de variables que el conteo de microaneurismas desempeña el papel más relevante en la discriminación de la enfermedad.
3. **Relación entre Exudados:** Al igual que con los microaneurismas, se observan clústeres de alta correlación entre los niveles de detección de exudados, particularmente entre **exudate2**, **exudate3** y **exudate4** (valores entre 0,92 y 1,00). Su correlación con la variable **Class** es positiva pero moderada (máximo de 0,18 en **exudate7**), indicando que, aunque son indicadores de RD, su peso diagnóstico individual en este dataset es menor al de los microaneurismas.

4. **Independencia de Rasgos Anatómicos:** Atributos como `macula_opticdisc_distance` (0,01) y `optic_disc_diameter` (-0,03) muestran una correlación prácticamente nula con la presencia de la enfermedad en este conjunto de datos. Esto sugiere que la patología se manifiesta principalmente a través de lesiones detectables (MA y exudados) antes de generar cambios anatómicos macroscópicos detectables por estos descriptores específicos.

4.5.2. Conclusión del Análisis de Correlación

El mapa de calor valida la hipótesis de que las lesiones retinales, específicamente los **microaneurismas detectados con niveles de confianza iniciales**, son los mejores predictores lineales de la patología en este dataset. Además, la fuerte colinealidad interna entre las variables de lesiones justifica el uso de pruebas de significancia que traten estos grupos como una dimensión común de daño neurovascular (Casanova et al., 2014).

4.6. Comparación de Grupos (Prueba Mann-Whitney U)

Tras confirmar en la sección anterior que las variables de microaneurismas (`ma1` a `ma6`) no siguen una distribución normal según el test de Shapiro-Wilk, se procedió a realizar un análisis inferencial de comparación de grupos mediante la prueba de Mann-Whitney U (Chacón Pacheco & Chavez Orellana, 2026). Esta prueba no paramétrica permite determinar si existen diferencias estadísticamente significativas en las medianas de los conteos de lesiones entre pacientes sanos (Clase 0) y pacientes con diagnóstico de retinopatía (Clase 1).

4.6.1. Planteamiento de Hipótesis

- Hipótesis Nula (H_0): No existe una diferencia significativa en la distribución del conteo de microaneurismas entre el grupo sano y el grupo con retinopatía diabética.
- Hipótesis Alternativa (H_1): Existe una diferencia significativa en la distribución

del conteo de microaneurismas entre ambos grupos.

4.6.2. Resultados de la Prueba

Los estadísticos obtenidos mediante la librería `scipy.stats` se detallan en la siguiente tabla:

Tabla 5: Resultados de la prueba Mann-Whitney U para microaneurismas.

Variable	U_statistic	p_value	Significativo
ma1	111208	$1,25 \times 10^{-21}$	Sí
ma2	116076	$3,67 \times 10^{-18}$	Sí
ma3	121532	$1,17 \times 10^{-14}$	Sí
ma4	127750	$3,73 \times 10^{-11}$	Sí
ma5	133506	$2,25 \times 10^{-08}$	Sí
ma6	139938	$8,62 \times 10^{-06}$	Sí

4.6.3. Interpretación de los Hallazgos

El análisis de los resultados permite extraer las siguientes conclusiones fundamentales para el estudio:

1. **Rechazo de la hipótesis nula:** En todos los niveles de confianza (α de 0,5 a 1,0), los p-valores son extremadamente bajos (siendo el mayor $8,61 \times 10^{-6}$ para **ma6**), situándose muy por debajo del umbral de significancia de 0,05. Esto permite rechazar H_0 y confirmar que las diferencias observadas entre pacientes sanos y enfermos no son producto del azar.
2. **Sensibilidad del diagnóstico:** Se observa que la significancia estadística es más aguda en los niveles de confianza iniciales (**ma1** y **ma2**). El p-valor más bajo se registró en **ma1** ($1,25 \times 10^{-21}$), lo que sugiere que el conteo de lesiones detectadas incluso con una sensibilidad moderada ($\alpha = 0,5$) es un potente discriminador de la enfermedad.

3. **Consistencia con la literatura:** Estos resultados validan empíricamente lo expuesto por Casanova et al. (2014), quienes identifican al conteo de microaneurismas como el rasgo de mayor importancia diagnóstica entre todas las variables extraídas de imágenes de fondo de ojo.
4. **Confirmación de biomarcadores:** La prueba estadística ratifica lo observado visualmente en los diagramas de caja y en el análisis de valores atípicos, consolidando al recuento de MA como un biomarcador clínico robusto para la clasificación automatizada en este dataset.

4.7. Modelamiento mediante Regresión Logística

Para modelar la probabilidad de presencia de retinopatía diabética en función de los descriptores clínicos y anatómicos, se implementó un modelo de Regresión Logística. A diferencia de la regresión lineal, este método es el estándar estadístico adecuado para variables dependientes binarias, como la variable `Class` de este estudio (0 = Sano, 1 = RD), permitiendo identificar qué factores incrementan significativamente el riesgo de padecer la patología.

4.7.1. Justificación de la Selección de Atributos

Para este modelo se seleccionó un subconjunto representativo de cuatro variables: `ma1`, `exudate1`, `macula_opticdisc_distance` y `opticdisc_diameter`. Se excluyeron los 15 atributos restantes por los siguientes criterios técnicos:

- **Prevención de la multicolinealidad:** El análisis de correlación previo demostró una colinealidad casi perfecta ($r \approx 1,0$) entre las variables de microaneurismas (`ma1`–`ma6`) y entre los niveles de exudados. Incluir variables altamente redundantes inflaría los errores estándar, invalidando la significancia de los coeficientes. Se seleccionaron `ma1` y `exudate1` como representantes de la carga lesional.
- **Representación dimensional:** El subconjunto elegido permite evaluar las tres dimensiones críticas del dataset: lesiones vasculares (MAs), depósitos lipídicos

(exudados) y rasgos anatómicos estructurales (distancia y diámetro del disco).

- **Parsimonia y relevancia clínica:** Siguiendo los hallazgos de Casanova et al. (2014), se priorizaron los microaneurismas por ser la variable de mayor importancia para la discriminación de la enfermedad, buscando un modelo eficiente que evite el “ruido” de variables con nulo aporte lineal.

4.7.2. Evaluación Global y Bondad de Ajuste

El modelo es estadísticamente significativo en su conjunto (**Prob (LLR)** de $4,091 \times 10^{-23}$). Sin embargo, el valor de **Pseudo R-squared** (0,0874) y el área bajo la curva AUC de 0,64 indican una capacidad predictiva moderada. Esto sugiere que, si bien el modelo identifica patrones relevantes, la relación entre los predictores y el diagnóstico presenta una complejidad que un modelo lineal simple no logra capturar en su totalidad.




Figura 3: Matriz de confusión y Curva ROC-AUC.

4.7.3. Interpretación de los Coeficientes y Significancia

Al analizar los resultados individuales de la regresión, se extraen las siguientes conclusiones:

- **Significancia crítica de microaneurismas (ma1):** Con un p-valor de 0,000 y un coeficiente positivo (0,0307), se confirma que el aumento en el conteo de lesiones vasculares eleva significativamente la probabilidad de diagnóstico positivo. Este hallazgo valida empíricamente la tesis de Casanova et al. (2014), situando a los MAs como el biomarcador más robusto para la clasificación automatizada.
- **Impacto de exudados (exudate1):** Esta variable también resultó ser un predictor significativo (p-valor = 0,000), reafirmando que la presencia de depósitos de lípidos es un indicador primario de la patología en este dataset.
- **Irrelevancia de rasgos anatómicos:** Tanto la distancia mácula-disco ($p = 0,632$) como el diámetro del disco ($p = 0,330$) no mostraron significancia estadística. Esto sugiere que, para este conjunto de datos, las lesiones retinales son predictores mucho más potentes de la enfermedad que las variaciones en la estructura geométrica básica del ojo.

4.7.4. Evaluación de Desempeño (Matriz de Confusión y ROC)

La capacidad de clasificación del modelo se evaluó mediante los resultados en el conjunto de prueba:

1. Matriz de Confusión:

- **Verdaderos Positivos (TP):** 72 pacientes con RD correctamente identificados.
- **Verdaderos Negativos (TN):** 66 pacientes sanos correctamente identificados.
- **Falsos Negativos (FN):** 51 casos de RD no detectados, lo que arroja una sensibilidad del 58,5 %.
- **Falsos Positivos (FP):** 42 casos sanos clasificados erróneamente, resultando en una especificidad del 61,1 %.

2. **Curva ROC-AUC:** El valor obtenido de 0,64 sitúa el desempeño del modelo por encima del azar (0,5), pero significativamente por debajo de los estándares de alta precisión clínica, como el 0,989 alcanzado por sistemas de ensamble en la literatura (Casanova et al., 2014). Esto confirma que las cuatro variables seleccionadas son necesarias pero insuficientes para un diagnóstico automatizado de alta fidelidad, requiriendo modelos de inteligencia computacional más robustos.

5. Conclusiones

El análisis estadístico e inferencial realizado sobre el dataset **Diabetic Retinopathy Debrecen** permitió validar las hipótesis fundamentales sobre la naturaleza de la patología y la relevancia de sus biomarcadores.

5.1. Síntesis de Hallazgos Principales

Se confirmó matemáticamente la **no normalidad** de las variables de lesiones y una marcada asimetría positiva, coherente con la distribución clínica de la enfermedad. La validación de outliers mediante el método de Tukey fue determinante: el 100 % de los valores extremos **pertenecen a la Clase 1**, demostrando que los recuentos elevados de microaneurismas son indicadores inequívocos de estadios severos de la RD.

5.2. Discusión de Resultados y Desempeño del Modelo

Las pruebas de **Mann-Whitney U** y la **Regresión Logística** coinciden en señalar a los microaneurismas (**ma1**) como la variable de mayor peso diagnóstico ($p < 0,05$), respaldando lo expuesto por Casanova et al. (2014). No obstante, la evaluación de desempeño reveló limitaciones críticas: una sensibilidad del 58,5 % y un AUC de 0,64. Estos valores indican que, aunque la carga lesional es un indicador estadísticamente significativo, un modelo logístico lineal no es suficiente para discriminar con precisión entre clases, especialmente en etapas tempranas donde el solapamiento de datos es alto (según se observó en los diagramas de caja).

5.3. Limitaciones y Proyecciones Futuras

La principal limitación radica en la incapacidad del modelo lineal para capturar la variabilidad total del diagnóstico ($\text{Pseudo } R^2 = 0,087$). Como proyección futura, se hace imperativo el uso de algoritmos de inteligencia computacional no lineales, como *Random Forests* o redes neuronales, que puedan explotar la alta colinealidad detectada en el mapa de calor y mejorar la tasa de detección de casos positivos, acercándose a los

niveles de sensibilidad clínica exigidos para sistemas de cribado automático.

Anexos

Referencias

- Antal, B., & Hajdu, A. (2014a). Diabetic Retinopathy Debrecen. <https://doi.org/10.24432/C5XP4P>
- Antal, B., & Hajdu, A. (2014b). An ensemble-based system for automatic screening of diabetic retinopathy. *Knowledge-Based Systems*. <https://doi.org/10.1016/j.knsys.2014.01.007>
- Casanova, R., Saldana, S., Chew, E. Y., Danis, R. P., Greven, C. M., & Ambrosius, W. T. (2014). Application of Random Forests Methods to Diabetic Retinopathy Classification Analyses. *PLoS ONE*, 9(6), e98587. <https://doi.org/10.1371/journal.pone.0098587>
- Chacón Pacheco, M., & Chavez Orellana, S. (2026). *Laboratorio 1: Análisis Estadístico Descriptivo e Inferencial* [Documento de cátedra para el curso de Inteligencia Computacional]. Universidad de Santiago de Chile. Santiago, Chile.
- Chavez Orellana, S. (2026). Presentación Laboratorio 1: Análisis Estadístico Descriptivo e Inferencial [Apunte de apoyo para la implementación técnica].
- Kelly, M., Longjohn, C., & Nottingham, K. (2023). ucimlrepo: Python wrapper for the UCI Machine Learning Repository. <https://github.com/uci-ml-repo/ucimlrepo>
- Team, T. P. D. (2024, febrero). *pandas-dev/pandas: Pandas* (Ver. latest). Zenodo. <https://doi.org/10.5281/zenodo.3509134>
- Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, 17, 261-272. <https://doi.org/10.1038/s41592-019-0686-2>
- Waskom, M. L. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>